

8. 자연어 처리

1. 자연어의 특성
2. 한국어 문법
3. 형식 문법
4. 자연어 처리의 분석 단계
5. 형태소 분석과 품사 태깅
6. 구문 분석
7. 의미 분석
8. 단어의 실수 벡터 표현
9. 딥러닝 기반의 자연어처리
10. 음성인식

1. 자연어의 특성

❖ 언어

- 인간이 사용하는 가장 자연스러운 정보전달 및 의사표현 수단
- 컴퓨터 인터페이스로서 필수적 요소
- **자연어** (自然語, natural language)
 - 특정 집단이 모국어로 사용하는 자연발생적인 언어
- **인공 언어**
 - 특정 목적을 위해 인위적으로 만들어진 언어
 - 자연언어에 비해 엄격한 문법구조
 - 형식 언어(formal language), 프로그래밍 언어, 에스페란토어

❖ **자연어 처리**(natural language processing, **NLP**)

- 컴퓨터를 사용하여 인간의 언어를 분석하고 이해하여 활용하려는 분야

자연어의 특성

❖ 자연어의 특성

- 언어별 고유한 특성
- 띄어쓰기
 - 한글/영어 vs 일본어/중국어
- 활용(活用, conjugation) 변환의 정도
 - 한글 : 동사, 형용사의 심한 활용
 - 영어 : 동사의 비교적 규칙적인 활용

자연어의 특성

❖ 형태적 구조에 따른 언어 분류

- **고립어**(孤立語, isolating language)
 - 단어가 의미만 나타내고 형태의 변화가 없으며, 어순에 따라 문법적 관계 결정
 - 중국어, 태국어, 베트남어
- **굴절어**(屈折語, inflective language)
 - 어근(語根, root)과 접사(接辭, 접두사/접미사)가 쉽게 분리되지 않는 형태
 - 성, 수, 격, 시제, 법에 따라 단어가 변하는 언어
 - 영어, 프랑스어, 라틴어
- **교착어**(膠着語, agglutinating language)
 - 어근에 문법형태소인 접사를 붙여 단어를 파생시키거나 문법적 관계를 나타내는 언어
 - 한국어, 일본어
- **포함어**(抱合語, incorporative language)
 - 문장을 구성하는 요소가 서로 밀접하게 결합되어 마치 전체 문장이 하나의 단어를 이루는 것처럼 보이는 구조의 언어
 - 에스키모어, 아메리카 인디언어, 호주 원주민어

2. 한국어 문법

❖ 한국어 문법

- **형태론** (形態論, morphology)
 - 단어의 형태 변화와 그 구성에 관련된 규칙을 다루는 문법 분야
- **통사론** (統辭論, syntax)
 - 어떤 순서로 단어를 배열해야 문장이 되는가에 대한 문장 구성, 구성요소 간의 관계 및 기능을 다루는 분야
- **음운론** (音韻論, phonology)
 - 음운의 성질, 소리와 소리가 만나면 생기는 변화를 다루는 분야

한국어 문법

❖ 형태론(形態論, morphology)

- 형태소들을 결합하여 어절을 형성하는 체계와 규칙, 낱말의 특징을 다룸
- 음절(音節, syllable)
 - 한 번에 소리 낼 수 있는 소리 단위
 - 문장을 소리 나는 대로 쓸 때 글자 한 자에 대응하는 것
 - 예. '산에 눈이 내린다' ⇒ [사네누니내린다]
 - » [사], [네], [누], [니], [내], [린], [다]
- 어절(語節)
 - 띄어쓰기가 되어 있는 말의 덩어리
 - 예. [산에], [눈이], [내린다]
- 어근(語根, root)
 - 단어형성(單語形成, word-formation)에서 그 단어의 뜻을 나타내는 최소 의미 단위

한국어 문법

❖ 형태론 – cont.

- 접사(接辭, affix)
 - 단어를 형성할 때 어근에 붙어 그 뜻을 제한하는 주변 부분
 - 어근 앞에 오는 **접두사**, 어근 뒤에 오는 **접미사**
- 어간(語幹, stem)
 - 동사, 형용사와 같은 용언이 활용할 때 변하지 않는 부분
- 어미(語尾, ending)
 - 용언을 활용할 때 어간에 붙어서 변화하는 부분
 - ‘치숫다’ = ‘치’(접두사), ‘치숫’(어근) + ‘다’(어미)
 - **어말 어미**(語末 語尾)
 - 단어의 끝자리에 들어가는 어미
 - 하나의 어간에 어말어미는 하나
 - **선어말 어미**(先語末 語尾)
 - 어말 어미의 앞자리에 들어가는 어미
 - 선어말어미는 여러 개 결합 가능

하- 시 었 겠 사오 버 니 ㄴ 다

(어근) (존경법) (과거) (추측) (공손) (합쇼체) (직설법) (원칙법) (어말어미)
(선어말 어미)

한국어 문법

❖ 형태소(形態素, morpheme)

- 의미를 가지는 요소로서 더 이상 분해할 수 없는 가장 작은 문법 단위
- 분해하면 뜻을 잃어버리게 되는 언어의 최소 단위

▪ 자립여부에 따른 분류

- 자립형태소
 - 자립적이어서 자신이 무슨 뜻인지 알 수 있게 하는 것
- 의존형태소
 - 자기가 가진 의미를 나타내려면 다른 말에 의존해서 합해져야 하는 것

▪ 실질적 의미 포함 여부에 따른 분류

- 어휘형태소 (실질형태소)
 - 개별적인 뜻이 사전에 나와 있는 형태소
- 문법형태소 (형식형태소)
 - 문법적 기능을 나타내는 형태

‘할 수 없지’

하-(의존형태소, 어근)/-르(의존형태소, 관형사적 접사)/수(자립형태소, 의존 명사)/
없(의존형태소, 어근)/-지(의존형태소, 어말 굴절 접사)

한국어 문법

❖ 품사(品詞, part-of-speech; POS)

- 단어를 **문법적 성질**의 공통성에 따라 몇 갈래로 묶어 놓은 것
- **역할**에 따른 분류
 - 체언, 용언, 수식언, 관계언, 독립언
- **의미**에 따른 분류 (9품사)
 - 명사, 대명사, 수사, 동사, 형용사, 관형사, 부사, 조사, 감탄사
 - 체언(體言)
 - 명사, 대명사, 수사
 - 용언(用言)
 - 동사, 형용사
 - 수식언(修飾言)
 - 관형사, 부사
 - 관계언(關係言)
 - 조사
 - 독립언(獨立言)
 - 감탄사

한국어 문법

❖ 품사 – cont.

- **명사**(名詞, noun)
 - 물건이나 장소, 사건, 추상적 개념과 같은 이름을 나타내는 것
- **대명사**(代名詞, pronoun)
 - 명사를 대신하는 지시하는 단어
- **수사**(數詞, numeral)
 - 수량이나 순서를 나타내는 단어
- **동사**(動詞, verb)
 - 사물의 움직임을 나타내는 말
 - 활용 변환을 하고 어간과 어미로 구성
- **형용사**(形容詞, adjective)
 - 사물의 성질이나 상태를 나타내는 말
 - 활용 변환을 하고 어간과 어미로 구성
- **관형사**(冠形詞, determiner)
 - 체언 앞에서 그 체언을 꾸며 주는 말
- **부사**(副詞, adverb)
 - 용언을 꾸며주는 말
- **감탄사**(感歎詞, interjection)
 - 화자의 부름, 놀람, 느낌, 대답을 나타내는 독립언
- **조사**(助詞, postposition)
 - 체언에 붙어 체언에 일정한 자격을 부여하는 말

한국어 문법

❖ 통사론(統辭論, syntax)

- **문장**(文章, sentence)
 - 말하는 사람의 생각을 **온전하게 나타내는 말의 묶음** 중에서 가장 작은 단위
 - 기본적으로 주어와 서술어로 구성
 - 단문(短文), 복문(複文)
- **절**(節, clause)
 - 복문에서 주어와 서술어 관계인 부분
- **구**(句, phrase)
 - 절은 아니지만 어절이 몇 개 뭉쳐서 **의미적 기능**을 하는 것
- **문장성분**(文章成分)
 - 어절을 역할에 따라 **주어, 목적어, 서술어, 보어, 관형어, 부사어, 독립어**로 분류한 것

심청이는 빨간 연꽃을 매우 좋아했다.
주어 관형어 목적어 부사어 서술어

그래서 심청이는 왕비가 되었다.
독립어 주어 보어 서술어

한국어 문법

❖ 음운론 (音韻論, phonology)

- 음운의 성질, 소리와 소리가 만나면 생기는 변화를 다루는 분야
- 음성인식 분야의 중요한 기반 이론
- **음운(音韻)**
 - 음소(音素, phoneme) : 자음, 모음
 - 운소(韻素, prosodeme) : 소리의 길이, 높낮이, 세기
- **음운현상**
 - 음절의 끝소리 규칙, 자음동화, 구개음화, 모음조화
 - 움라우트(' | '역행동화), 원순모음화, 전설모음화
 - 음운 축약·탈락, 사잇소리 현상, 된소리되기 등

3. 형식 문법

❖ 형식 문법(formal grammar)

- 특정 형식 언어에 속하는 **스트링**(string, 상황에 따라 문자열 또는 문장)을 생성하는 데 사용되는 유한개의 **생성 규칙**(production rule)들의 집합

❖ 형식 언어(formal language)

- 특정 **형식 문법에 따라 생성될 수 있는 모든 스트링의 집합**
- 용도
 - 문법으로부터 스트링들을 생산해 내는 **생성 문법**(generative grammar)
 - 문자열이 특정 언어에 포함되는지를 판단하는 **해석 문법**(analytic grammar)

❖ 형식문법 종류

- **노엄 촘스키**(Avram Noam Chomsky)의 분류
 - 정규 문법(Type-3 문법), 문맥 자유 문법(Type-2 문법), 문맥 의존 문법(Type-1 문법), 무제약 문법(Type-0 문법)



1928.12.7-

형식 문법

❖ 형식언어 문법 G

$$G = (N, \Sigma, P, S)$$

- N : 비단말 기호 (nonterminal symbol)
- Σ : 단말 기호
- P : 생성 규칙의 집합
- S : 시작 기호

❖ 정규 문법(regular grammar, Type-3 grammar)

▪ 우선형(right linear) 문법

$$A \rightarrow a$$

$$A \rightarrow aB$$

$$A \rightarrow \epsilon$$

▪ 좌선형(left linear) 문법

$$A \rightarrow a$$

$$A \rightarrow Ba$$

$$A \rightarrow \epsilon$$

$$A \in N \cup \{S\}$$

$$a \in \Sigma,$$

$$\epsilon$$

형식 문법

❖ 정규 언어(regular language)

- 정규 문법을 사용하여 생성되는 언어
- 정규식(regular expression)으로 표현 가능
- 유한 상태 기계(finite state machine)로 정규식 인식 가능

표 8.1 정규식 표현 방법

메타문자	의미	사용례
.	어떤 문자나 하나	.at hat, cat과 같이 at로 끝나는 3문자 문자열
[]	대괄호[] 문자 하나	[aeiou] a,e,i,o,u중의 한 글자 [A-Z] 영문자 대문자 중 하나 [A-Za-z0-9] 영문자, 숫자 중 하나
[^]	대괄호 안의 문자를 제외한 문자	[^hc]at hat, cat을 제외한 .at
^	문자열의 첫번째 위치, 행(line) 기반 도구에서 행의 첫번째 위치	^hat hat으로 시작하는 행 또는 문자열
\$	문자열의 마지막 위치, 행 기반도구에서 개행 문자 이전 위치	cat\$ cat으로 끝나는 행 또는 문자열
*	이전 문자를 0회 이상 반복	ba* ba, baa, baaa와 같은 표현 [xy]* x와 y를 사용해서 만들 수 있는 모든 문자열
+	이전 문자를 1회 이상 반복	ba+ baa, baaa 등 표현
?	이전 문자를 0 또는 1회 반복	ba? b 또는 ba
	양쪽에 있는 것 중에서 하나 선택	cat dog cat 또는 dog
\w, \w?	점(.) 하나, 물음표(?) 하나	
\wb \WB	접두사	\wbun\WB un으로 시작하는 단어

형식 문법

❖ 문맥 자유 문법(context-free grammar, Type-2 grammar)

$$A \rightarrow w$$

$$A \in N \cup \{S\}$$

$$w \in (N \cup \Sigma)^* - \{\epsilon\}$$

- 프로그래밍 언어의 문법
- 컴파일러는 기본적으로 문맥 자유 문법을 다룸
- 정규 언어는 문맥 자유 언어의 부분 집합

형식 문법

❖ 문맥 의존 문법(context-sensitive grammar, Type-1 grammar)

- 생성규칙의 LHS(left hand side)는 시작부분과 끝부분 포함

$$\alpha A \beta \rightarrow \alpha \gamma \beta$$

$$A \in N,$$

$$\alpha, \beta \in (N \cup \Sigma)^*$$

$$\gamma \in (N \cup \Sigma)^+$$

- 비단말 기호 A 를 기호 양 옆의 상황에 따라, 즉 문맥에 따라 다르게 대치 가능
- 문맥 자유 언어는 문맥 의존 언어에 포함

형식 문법

❖ 무제약 문법(unrestricted grammar, Type-0 grammar)

- 가장 일반적인 형식 문법

$$\alpha \rightarrow \beta$$

$$\alpha \in (N \cup S \cup \Sigma)^+$$

$$\beta \in (N \cup S \cup \Sigma)^*$$

- 생성 규칙을 정의하는데 제약이 없음
- 튜링 머신(Turing machine)은 무제약 문법의 문장 인식 가능




그림 8.1 형식 언어와 포함 관계

4. 자연어 처리의 분석 단계

❖ 자연어 처리 분석 단계



그림 8.2 자연어 처리 분석 단계.

- **형태소 분석**(morphological analysis)
 - 입력된 문자열을 분석하여 형태소 단위로 분해하는 과정
- **구문 분석**(syntactic analysis)
 - **구문**(syntax)에 따라 문장이 가지는 **구문 구조**를 분석하여, 문장을 구성하는 **문자열**들이 문장에서 어떤 **역할**을 하는지 **결정**
 - **구문(syntax)** : 문장이나 구절을 만드는 규칙
 - '나는 책을 읽는다' = 나는(**주어**) + 책을(**목적어**) + 읽는다(**서술어**)
 - 구문 분석 결과는 **파스 트리**(parse tree) 형태로 표현
 - **파싱**(parsing)
 - 문장을 구문 분석하여 파스 트리를 만들어 내는 작업

자연어 처리의 분석 단계

❖ 자연어 처리 분석 단계 – cont.



- **의미 분석**(semantic analysis)
 - 구문 분석의 결과를 해석하여 **문장의 의미**를 결정하는 것
- **화용 분석**(pragmatic analysis, 話用/語用 分析)
 - 실제 **상황적 맥락** 즉, 말하는 이와 듣는 이의 관계, 시간과 장소, 주제를 **고려**하여 문장이 **실세계**와 가지는 **연관 관계**를 **분석**하는 것

가게 손님 : '우유 있어요?'

점원: (손님이 우유를 사려고 한다!) '우유는 오른쪽 통로에 있어요'

5. 형태소 분석과 태깅

❖ 형태소 분석

- 자연어 처리의 가장 기본적인 분석 작업
- **단어**(한국어의 경우, 어절)에 대하여, **형태소**들을 인식
- 불규칙한 활용이나 축약, 탈락 현상이 일어난 경우에 원형 복원
- **어휘 분석**(lexical analysis)이라고도 함
- 여러 **사전**(辭典, dictionary) **정보** 이용
 - 문법형태소 사전, 어휘형태소 사전, 전문 용어 사전, 사용자 정의 사전, 기분석 사전
- **규칙**(rule) 기반 분석
- 언어별 난이도 차이
 - 영어, 프랑스어 : 쉬움
 - 한국어, 일본어, 아랍어 : 어려움

5.1 형태소 분석

❖ 형태소 분석 - 영어

- 규칙변환 및 불규칙 변환 명사와 동사
 - 규칙
 - Walk, walks, walking, walked, walked
 - Table, tables
 - 불규칙
 - Eat, eats, eating, ate, eaten
 - Catch, catches, catching, caught, caught
 - Cut, cuts, cutting, cut, cut
 - Goose, geese
- 형태소 분석의 예
 - Cats cat +N +PL
 - Cat cat +N +SG
 - Cities city +N +PL
 - Merging merge +V +Present-participle
 - Caught catch +V +Past-participle

N : noun(명사)

PL: plural (복사)

SG: singular (단수)

V: 동사

Present-participle (현재분사)

Past-participle (과거분사)

형태소 분석

❖ 형태소분석 - 한글

- 교착어의 특성 때문에 영어에 비해 복잡

- **중의성**(ambiguity) 포함

- 예 : '나는'

- 나(대명사, I) + 는 (조사),
- 나(동사, produce) + 는 (어미)
- 날(동사, fly) + 는 (어미)

- 접두사, 접미사 처리

- 형태소 결합의 예 : **친구에게서였었다라고**

친구(명사) + 에게(조사) + 서(조사) + 이(서술격조사) + 었(과거시제어미) + 었(회상어미) + 다(어말어미) + 라고(인용격조사)

형태소 분석

❖ 한국어 형태소 분석 과정




그림 8.3 한국어 형태소 분석의 단계

형태소 분석

❖ 형태소 분석의 활용 - 한국어

- 맞춤법이나 띄어쓰기 교정
- 단어의 품사 결정 정보 제공
- 단어의 의미 추정 정보 제공
- 검색엔진 색인(index) 구성

❖ 형태소 분석의 활용 - 영어

- 철자교정 : reference
- 하이픈 위치 결정(hyphenation) : refer-ence
- 품사(Part-of-Speech, POS) 분석 : google, googler
- 음성합성(text-to-speech, TTS)
 - hothouse (/t/, /θ/)
- 단어의 의미 추정
 - 'Twas brillig and the slithy toves...
- 기계번역
- 색인(indexing) : 검색 엔진

형태소 분석

❖ 한글 형태소 분석기

- 국민대학교 KLT
- KAIST 한나눔
- 서울대학교 꼬꼬마
- 기타

❖ 영어 형태소 분석기

- OpenNLP
- HFST(www.ling.helsinki.fi/kieliteknologia/tutkimus/hfst/),
- foma(foma.googlecode.com)
- 기타

5.2 품사 태깅

❖ 품사 태깅(POS tagging)

- 문장의 각 단어에 품사의 범주 및 문법적 기능에 대한 태그(tag, 꼬리표)를 붙이는 것
- 말뭉치(corpus)
 - 언어 연구를 위해 컴퓨터가 읽을 수 있는 형태로 텍스트를 모아 놓은 것
- 주석 처리된 말뭉치를 이용한 품사 태깅 방법

대한민국은 무척 아름다운 나라이다.

'대한민국'_N '은'_J '무척'_M '아름답'_P '은'_E '나라'_N '이'_J '다' E '.'_S

A man see a woman with a telescope on the hill.

A_AT0 man_NN1 see_VVB a_AT0 woman_NN1 with_PRP a_AT0 telescope_NN1
on_PRP the_AT0 hill_NN1.

AT0: 관사
NN1: 단수명사
VVB: 동사기본형
PRP: 전치사

품사 태깅

❖ 품사 태깅 기법

▪ 규칙 기반 방법

- 문장 구성의 원리, 문맥적인 정보와 형태소 정보 등을 이용하여 수작업으로 만든 규칙 사용
- 일관성있는 규칙을 많이 만들어내기는 어렵지만, 만들어진 규칙은 비교적 쉽게 사용 가능

▪ 기계학습 기반 방법

- 품사 태깅이 되어있는 말뭉치를 학습 데이터로 사용하여 분류기를 학습하여 사용
- 통계적 기계학습 알고리즘
 - 은닉 마르코프 모델(HMM), 최대 엔트로피 마르코프 모델(MEMM), 조건부 랜덤 필드(CRF) 등
- SVM
- 딥러닝 신경망

품사 태깅

❖ 은닉 마르코프 모델 기반 품사 태깅 방법

- w_i : 단어
- $tag(w_i)$: 단어 w_i 의 품사
- $T = \{t_1, t_2, \dots, t_n\}$: 품사의 집합
- 문장에서 인접한 단어 간의 품사에 대한 전이확률 $P = (p_{ij})_{n \times n}$ 계산
- 품사 t_i 별로 단어 w_j 의 출현확률 $P(w_j|t_i)$ 계산
- 인접한 두 단어 w_1 와 w_2 , $tag(w_1) = A$ 일 때, $tag(w_2) = B$ 일 확률

$$P(tag(w_2) = B) = p_{AB} \cdot P(w_2|B)$$

- 단어 w_2 에 부여할 되는 품사 B^*

$$B^* = \max_B p_{AB} \cdot P(w_2|B)$$

5.3 개체명 인식

❖ 개체명 인식(named entity recognition)

- 텍스트에서 **인명, 지명, 기관명, 시간, 날짜, 화폐, 퍼센티지**와 같은 **개체명**을 인식하여 텍스트에 해당 객체명 **태그**를 달아주는 것
- 정보검색, 정보추출, 질의응답에서 중요한 역할
- **"자베르 경감이 장발장과 1832년 파리에서 마주쳤다"**

[자베르]_{인명} 경감이 [장발장]_{인명}과 [1832]_{날짜}년 [파리]_{지명}에서 마주쳤다

개체명 인식

❖ 개체명 인식 기법

▪ 규칙 기반의 방법

- 개체명을 인식하기 위해 사전들과 규칙들 이용
- 사전의 종류
 - **개체명 사전** : 인명, 지명, 조직명 등의 개체명에 대한 직접적인 정보
 - **결합 단어 사전** : 개체명과 함께 붙어서 나타나는 단어 정보
- 개체명 인식 규칙
 - **단어구성 규칙** : 개체명의 후보가 되는 단어 자체의 정보 이용
 - **문맥 규칙** : 문장에서 개체명의 후보가 되는 단어의 주변 정보 이용

▪ 기계학습 기반의 방법

- 단어의 품사 정보, 문자 유형, 주변 단어 정보, 사전 정보 등의 특징들을 이용하여 개체명을 부류로 간주하여 분류기 개발

6. 구문 분석

❖ 구문 분석(syntactic analysis)

- 구문에 따라 주어진 문장에서 단어들의 역할을 파악하여 문장을 계층적인 트리 구조로 변환하는 작업
- 구문(syntax)
 - 문장이나 구절을 만드는 규칙
 - 생성 규칙을 사용한 언어 정의 예
- 구문 분석 접근 방법
 - 규칙 기반 구문 분석
 - 기계학습 기반 구문 분석

6.1 규칙 기반 구문 분석

❖ 규칙 기반 구문 분석

- 문맥 자유 문법 형태의 구구조 문법(句構造 文法)을 이용하여 문장 분석
- 구구조 문법
 - 문장의 문법을 $N, V, Adj, DetP$ 등의 품사 기호와, $NP, VP, AdjP$ 등의 구(句) 기호를 사용하여 문맥 자유 문법 형태로 기술

- 1) $S \rightarrow NP VP$
- 2) $VP \rightarrow V NP$
- 3) $NP \rightarrow DetP N \mid AdjP NP$
- 4) $AdjP \rightarrow Adj \mid Adv AdjP$
- 5) $N \rightarrow boy \mid girl$
- 6) $V \rightarrow sees \mid likes$
- 7) $Adj \rightarrow big \mid small$
- 8) $Adv \rightarrow very$
- 9) $DetP \rightarrow a \mid the$

The boy likes a girl.




그림 8.4 파스 트리

(S (NP (DetP the) (N boy)))

(VP (V likes) (VP (DetP a) (N girl))))

규칙 기반 구문 분석


❖ 파서(parser) 또는 구문 분석기(syntactic analyzer)

- 파싱(parsing)을 수행하는 프로그램

❖ 파싱 기법 분류

- 트리 구조의 생성 진행 방향에 따라
- 하향식(top-down) 파싱
- 상향식(bottom-up) 파싱

The boy likes a girl.



규칙 기반 구문 분석

❖ 하향식(top-down) 파싱

- 문장 시작 기호 S 에서 시작
- 생성 규칙을 반복 적용하여 주어진 문장을 얻는 과정을 통해 구문의 구조 파악

The boy likes a girl.

1) $S \rightarrow NP VP$

2) $VP \rightarrow V NP$

3) $NP \rightarrow DetP N \mid AdjP NP$

4) $AdjP \rightarrow Adj \mid Adv AdjP$

5) $N \rightarrow boy \mid girl$

6) $V \rightarrow sees \mid likes$

7) $Adj \rightarrow big \mid small$

8) $Adv \rightarrow very$

9) $DetP \rightarrow a \mid the$

$S \rightarrow NP VP$ (규칙 1 적용)

$\rightarrow DetP N VP$ (규칙 3 적용)

$\rightarrow the N VP$ (규칙 9 적용)

$\rightarrow the boy VP$ (규칙 5 적용)

$\rightarrow the boy V NP$ (규칙 2 적용)

$\rightarrow the boy likes NP$ (규칙 6 적용)

$\rightarrow the boy likes DetP N$ (규칙 3 적용)

$\rightarrow the boy likes a N$ (규칙 9 적용)

$\rightarrow the boy likes a girl$ (규칙 5 적용)

규칙 기반 구문 분석

❖ 상향식(bottom-up) 파싱

- 문장에서 시작하여 문장 시작 기호 S 방향으로 파싱 트리를 생성
- 생성 규칙의 오른쪽(RHS, right hand side)에 대응하는 부분을 해당 규칙의 왼쪽 부분(LHS)으로 변화하는 과정 반복

The boy likes a girl.

- | | |
|---|---|
| 1) $S \rightarrow NP VP$ | $The\ boy\ likes\ a\ girl. \rightarrow DetP\ boy\ likes\ a\ girl$ (규칙 3 적용) |
| 2) $VP \rightarrow V NP$ | $\rightarrow DetP\ N\ likes\ a\ girl$ (규칙 5 적용) |
| 3) $NP \rightarrow DetP N \mid AdjP NP$ | $\rightarrow NP\ likes\ a\ girl$ (규칙 3 적용) |
| 4) $AdjP \rightarrow Adj \mid Adv AdjP$ | $\rightarrow NP\ V\ a\ girl$ (규칙 6 적용) |
| 5) $N \rightarrow boy \mid girl$ | $\rightarrow NP\ V\ DetP\ girl$ (규칙 3 적용) |
| 6) $V \rightarrow sees \mid likes$ | $\rightarrow NP\ V\ DetP\ N$ (규칙 5 적용) |
| 7) $Adj \rightarrow big \mid small$ | $\rightarrow NP\ VNP$ (규칙 3 적용) |
| 8) $Adv \rightarrow very$ | $\rightarrow NP\ VP$ (규칙 2 적용) |
| 9) $DetP \rightarrow a \mid the$ | $\rightarrow S$ (규칙 1 적용) |

규칙 기반 구문 분석

❖ 구문 분석의 어려움

- 하나의 문장이 여러 구문 구조로 해석될 수 있는 **중의성**(重義性)
- **구조적 중의성**(structural ambiguity)
 - 하나의 **문장**이 다수의 구조로 해석될 수 있는 성질
- **어휘적 중의성**(lexical ambiguity)
 - 하나의 **단어**가 **여러 품사**로 사용될 때 발생하는 다수 구조로 해석될 수 있는 성질

규칙 기반 구문 분석

❖ 구조적 중의성(structural ambiguity)

$S \rightarrow NP VP$

$NP \rightarrow N \mid DetP N \mid NP PP$

$VP \rightarrow V NP \mid VP PP$

$PP \rightarrow P NP$



$N \rightarrow Tom \mid Jerry \mid park$

$V \rightarrow saw \mid caught$

$DetP \rightarrow a \mid the$

$P \rightarrow in$

Tom saw Jerry in the park.





규칙 기반 구문 분석

❖ 어휘적 중의성(lexical ambiguity)

Time flies like an arrow.

$S \rightarrow NP VP$
 $NP \rightarrow N \mid DetP N \mid Adj$
 $VP \rightarrow V \mid VP NP \mid VP PP$
 $PP \rightarrow P NP$
 $N \rightarrow Time \mid flies \mid arrow$
 $V \rightarrow flies \mid like$
 $DetP \rightarrow a \mid an \mid the$
 $Adj \rightarrow time$
 $P \rightarrow like$



규칙 기반 구문 분석

❖ 대표적인 파싱 기법


- 확장 전이망(augmented transition network)
- 차트 파싱(chart parsing)

❖ 확장 전이망 기반 파싱


- 언어의 각 생성문법을 유한상태기계(finite state automata)로 표현
 - 노드 : 상태
 - 방향성 있는 링크(directed link) : 전이(transition)
- 링크
 - 단어, 품사, 다른 전이망 호출, 분기 등의 라벨 부착
 - 다른 전이망 호출 라벨이 있으면 해당 전이망을 이용하여 해당 전이 부분 처리
- 파싱 결과
 - 문장이 주어지면 시작 상태 노드에서 시작하여 전이를 통해 승인상태로 도달하게 하는 전이 과정

규칙 기반 구문 분석

❖ 확장 전이망 기반 파싱 - cont.





The boy saw the girl with a flower.



규칙 기반 구문 분석

❖ 확장 전이망 기반 파싱 - cont.



규칙 기반 구문 분석

❖ 차트 파싱(chart parsing)

- 파싱의 중간과정에 부분적으로 완성되는 모든 구조들을 **차트(chart)**라는 **자료구조**에 저장
- 파싱 경로에 따라 **저장된 정보를 재활용**할 수 있게 만드는 **동적 계획법(dynamic programming)**에 기반한 방법
- **상향식(bottom-up)** 파싱에서 주로 이용
- 예. **CKY** (Cock-Kasami-Younger) **파싱** 알고리즘

규칙 기반 구문 분석

❖ CKY(Cock-Kasami-Younger) 파싱 알고리즘

- 차트 파싱의 일종
- Dynamic Programming 형태로 파싱 수행
- 상향식(bottom-up) 파싱

$$S \rightarrow NP VP$$
$$NP \rightarrow DetP N$$
$$VP \rightarrow V NP \mid VP PP$$
$$PP \rightarrow P NP$$
$$N \rightarrow boy \mid girl \mid flower \mid saw$$
$$V \rightarrow saw$$
$$P \rightarrow with$$

The boy saw the girl with a flower.

규칙 기반 구문 분석

❖ CKY 파싱 알고리즘 - 실행예

The boy saw the girl with a flower.

<i>DetP</i>							
the	<i>N</i>						
	boy	<i>V, N</i>					
		saw	<i>DetP</i>				
			the	<i>N</i>			
				girl	<i>P</i>		
					with	<i>DetP</i>	
						a	<i>N</i>
							flower

(a) 첫 번째 대각 칸 채우기

규칙 기반 구문 분석

❖ CKY 파싱 알고리즘 - 실행예

The boy saw the girl with a flower.

<i>DetP</i>	<i>NP</i>						
the	<i>N</i>						
	boy	<i>V, N</i>					
		saw	<i>DetP</i>	<i>NP</i>			
			the	<i>N</i>			
				girl	<i>P</i>		
					with	<i>DetP</i>	<i>NP</i>
						a	<i>N</i>
							flower

(b) 두 번째 대각 칸 채우기

규칙 기반 구문 분석

❖ CKY 파싱 알고리즘 - 실행예

The boy saw the girl with a flower.

<i>DetP</i> ④	<i>NP</i> ②			<i>S</i>			<i>S</i> ①
the	<i>N</i> ⑤						
	boy	<i>V</i> ⑧, <i>N</i>		<i>VP</i> ⑥			<i>VP</i> ③
		saw	<i>DetP</i> ①	<i>NP</i> ⑨			
			the	<i>N</i> ②			
				girl	<i>P</i> ③		<i>PP</i> ⑦
					with	<i>DetP</i> ⑤	<i>NP</i> ④
						a	<i>N</i> ⑥
							flower

(c) 최종 칸 채우기 결과

규칙 기반 구문 분석

❖ CKY 파싱 알고리즘 - 실행예




그림 8.9 CYK 차트파싱에 의한 파스 트리

6.2 기계학습 기반 구문분석

❖ 기계학습 기반 구문분석


- 구문 분석이 된 학습 데이터를 사용하여 구문 분석을 하는 모델을 학습을 통해 구축
- 사람이 구구조 문법을 정의할 필요가 없음
- 구문 분석된 정보를 포함한 말뭉치를 만들어서 제공
- 높은 신뢰도의 말뭉치 구축 필요
- **적용 모델**
 - SVM
 - 조건부 랜덤 필드(CRF) 모델
 - 딥러닝 신경망

기계학습 기반 구문분석


❖ 말뭉치

- 문장 하나하나를 구문 분석하여 말뭉치(corpus)로 구성해 놓은 것
- 구문 구조를 트리(tree)형태로 표현
- 한국어 : '21세기 세종계획' 말뭉치
- 영어 : Penn Treebank 말뭉치

```
(S (NP (NNP John))  
  (VP (VPZ loves)  
       (NP (NNP Mary))))  
(. .))
```



بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ
Chapter (67) sūrat l-mulk (Dominion)



기계학습 기반 구문분석

❖ The Penn Treebank : 품사 태깅 테스트(POS-tagged text)

Output of tagger

Battle-tested/NNP Japanese/NNP industrial/JJ managers/NNS
here/RB always/RB buck/VB up/IN nervous/JJ newcomers/NNS
with/IN the/DT tale/NN of/IN the/DT first/JJ of/IN
their/PP\$ countrymen/NNS to/TO visit/VB Mexico/NNP ,/,
a/DT boatload/NN of/IN samurai/NNS warriors/NNS blown/VBN
ashore/RB 375/CD years/NNS ago/RB ./.

Hand-corrected by annotator

Battle-tested/NNP*/JJ Japanese/NNP*/JJ industrial/JJ
managers/NNS here/RB always/RB buck/VB*/VBP up/IN*/RP
nervous/JJ newcomers/NNS with/IN the/DT tale/NN of/IN
the/DT first/JJ of/IN their/PP\$ countrymen/NNS to/TO
visit/VB Mexico/NNP ,/, a/DT boatload/NN of/IN
samurai/NNS*/FW warriors/NNS blown/VBN ashore/RB 375/CD
years/NNS ago/RB ./.

Final version

Battle-tested/JJ Japanese/JJ industrial/JJ managers/NNS
here/RB always/RB buck/VBP up/RP nervous/JJ newcomers/NNS
with/IN the/DT tale/NN of/IN the/DT first/JJ of/IN
their/PP\$ countrymen/NNS to/TO visit/VB Mexico/NNP ,/,
a/DT boatload/NN of/IN samurai/FW warriors/NNS blown/VBN
ashore/RB 375/CD years/NNS ago/RB ./.

Part-of-speech tagging pipeline

기계학습 기반 구문분석

❖ 한국어 treebank

- 괄호(bracket)를 사용하여 Penn Treebank와 유사하게 구성
- 구문분석 및 형태소 분석 포함

::A;25:1: 김 특무장, 아까 김 특무장이 지난 2주 동안 공병들이 대대 지역에서 열심히 작업을 해 왔다고 그랬다.

```
(S (NP-VOC 김/NPR
    특무장/NNC)
  ./SCM
  (ADVP 아까/ADV)
  (S (NP-SBJ 김/NPR
      특무장/NNC+이/PCA)
    (VP (S-COMP (NP-ADV 지난/DAN
        2/NNU
        주/NNX
        동안/NNX)
      (S (NP-SBJ 공병/NNC+들/XSF+이/PCA)
        (VP (VP (NP-ADV 대대/NNC
            지역/NNC+에서/PAD)
          (ADVP 열심히/ADV)
          (VP (NP-OBJ-LV 작업/NNC+을/PCA)
            (LV 하/VV+어/EAU)))
            모/VX+았/EPF+다고/ECS)))
        그러/VV+었/EPF+다/EFN))
    ./SFN)
```

7. 의미 분석

❖ 의미 분석(semantic analysis)

- 형태소 분석과 구문 분석 결과를 해석하여 문장이 가진 의미를 파악하는 작업
- 형태소 각각의 의미에 대한 지식 표현 필요
- 담화가 이루어지는 상황에 대한 **세계 모델**(world model)과 **상식**(common sense)에 대한 지식 필요
- 일반적인 상황에 대한 담화를 이해하는 것은 어려움
- **담화 환경의 제약**을 통해 만족스러운 정도의 시스템 구축 가능

의미 분석

❖ 질의응답(question-answering) 서비스

- 의미 분석은 자연어로 제시한 질문에 대한 답변
- 검색 기반 질의응답
 - 검색엔진과 같이 웹이나 데이터베이스에서 질문에 대한 답변을 찾아 제공
- 지식 기반 질의응답
 - 질의의 의미를 술어 논리식predicate logic expression으로 변환하여, 온톨로지 등의 정형화된 지식 베이스에 대해 논리적인 추론을 하여 답변
- 혼합형 질의응답
 - 웹 등의 텍스트 데이터 뿐만 아니라 지식 베이스도 함께 이용

의미 분석

❖ 단어 의미 중의성 해소(word sense disambiguation, 갈래뜻 판별)

- 특정 문장에 등장하는 단어가 어떤 의미인지 판별하는 작업

배를 타고 강을 건넜다.

배를 많이 먹었더니 배가 부르다.

물가가 배로 올랐다.

우리 학과 축구팀은 총장 배에서 우승했다.

❖ 화행 분석

- 대화 중의 발화utterance, 發話가 어떤 종류인지 파악하는 것
- 설명, 의견, 동의, 거부, 감사, 예-아니오 질문, 주관식 질문, 혼잣말, 재확인 등으로 분류

❖ 문맥 함의

- 문장에 표면적으로 나타난 사실이외에 함의 된 사실을 파악하는 것

“한글은 세종대왕이 창제했다.” ➡ “한글은 조선시대에 창제되었다”.

의미 분석

❖ 의미 분석

- 통사적으로 옳으나 의미적으로 틀린 문장이 있을 수 있음
 - 돌이 걸어간다 (*cf.* 사람이 걸어간다)
 - 바람이 달린다 (*cf.* 말이 달린다)
- 모호성 (ambiguity)
 - 말이 많다 (horse, speech)
- **통사(統辭)** : 생각이나 감정을 말로 표현할 때 **완결된 내용**을 나타내는 최소의 **단위**

8. 단어의 실수 벡터 표현

❖ 단어의 수치화

▪ one-hot 벡터

- 단어 별로 하나의 좌표 축을 대응시킨 공간에서, 해당되는 단어 위치에만 1을 설정하고 나머지는 0을 설정하여, 공간 상에 단어 표현

0	0	0	1	0	...	0	0	0	0
딸기	오이	참외	수박	배	...	복숭아	사과	귤	바나나

그림 8.11 '수박'의 one-hot 벡터표현의 예

$$\text{'수박'} = (0, 0, 0, 1, 0, \dots, 0, 0, 0, 0)$$

▪ 단점

- 단어간의 유사도를 계산하기 곤란

8.1 단어의 벡터표현

❖ Word2Vec 또는 단어 임베딩(word embedding)

- 단어의 의미를 충분히 잘 나타내도록 단어를 공간상의 실수 벡터로 표현

-0.1	0.03	0.5	0.8	-0.32	0.21
------	------	-----	-----	-------	------

그림 8.12 단어의 실수공간 벡터 표현

- 유사한 의미의 단어가 벡터공간 상에서 근처에 위치




그림 8.13 실수공간에서 단어 위치와 거리의 의미관계

8.2 CBOW 모델

❖ CBOW(Continuous Bag-of-Words) 모델

- V 차원의 one-hot 벡터로 표현된 단어를 N 차원의 실수 벡터로 바꾸는 역할
- **분포 가설**에 이론적 근거
 - '주변 단어들에 의해 단어 의미를 알 수 있다'
 - '나는 식사를 하기 전에 반드시 ____을 씻는다'
- 입력에 주변 단어들이 주어질 때, 출력에서는 해당 단어가 나타날 확률이 높아지도록 학습
- **단어를 표현하는 실수 벡터**
 - 학습된 모델에서 해당 단어의 노드에 연결된 가중치




그림 8.14 CBOW 모델

8.3 Skip-gram 모델

❖ Skip-gram 모델

- CBOW와 대칭적인 구조
- 입력에 학습 대상이 되는 단어가 주어질 때, 출력에서는 해당 단어의 주위 단어들이 나타날 확률이 높아지도록 학습
- 단어를 표현하는 실수 벡터
 - 학습된 모델에서 해당 단어의 노드에 연결된 가중치




그림 8.15 Skip-gram 모델

8.4 계층적 소프트맥스와 반례 표본 추출

❖ 계층적 소프트맥스

- 소프트맥스값을 계산할 때, 분모에서 모든 노드에 대한 계산 결과값이 필요 → 높은 계산 비용
- 소프트맥스를 이진 트리로 근사하여 계산시간을 절감하는 방법




그림 8.16 계층적 소프트맥스

$$p('강피') = v_{1l}v_{2r}v_{3l} = \sigma(w_1 \cdot h)(1 - \sigma(w_2 \cdot h))\sigma(w_3 \cdot h)$$

계층적 소프트맥스와 반례 표본 추출

❖ 반례 표본 추출

- 소프트맥스를 사용할 때 매번 많은 출력 벡터를 계산하는 대신, **표본을 추출**해서 이들에 대해서만 계산하는 방법
- 표본 구성
 - 학습 데이터에 주어진 전체 출력 단어들 w_i 와 소수의 반례 단어들 w_{n_j} 로 구성
- 각 학습 데이터의 목표 출력 단어 w_i 와 반례 단어들 w_{n_j} 에 한 오차 함수 E 를 최소화하도록 학습

$$E = -\log \sigma(u_i \cdot h) - \sum_{w_{n_j}} \log \sigma(-u_{n_j} \cdot h)$$

- 오차 함수가 소프트맥스의 값을 직접 사용하지 않기 때문에, 일반 소프트맥스를 사용하는 경우에 비하여 매우 짧은 시간에 CBOW나 Skip-gram 모델 학습 가능

8.5 단어 벡터 표현의 활용

❖ 단어 벡터 표현의 활용

- 단어 간의 유사도는 실수 벡터의 거리를 사용하여 직접 계산 가능
 - 유의어, 어근 비교, 시제 등에 한 정보 추출 또는 분석
 - 품사 태깅, 의미 분석, 관계 추출, 단위 의미 식별 등
- 수치 기반의 다양한 기계학습 알고리즘의 자연어 처리 적용 가능
 - 기계번역
 - 영상 주석달기 등

9. 딥러닝 기반의 자연어 처리

❖ 언어 모델(language model)

- 직전 n 개의 단어로 부터 다음에 나올 단어를 예측하는 모델

$$p(w_t | w_{t-1}, \dots, w_{t-n})$$

❖ 구와 문장의 벡터 표현

- 구(phase)와 문장(sentence)의 벡터표현




그림 8.18 반복 신경망

딥러닝 기반의 자연어 처리

❖ 기계 번역(machine translation)

- 입력 언어의 문장 s 를 다른 언어의 문장 t 로 변환할 때, 제로 된 번역일 확률이 가장 큰 문장 t' 을 선택하는 작업

$$t' = \operatorname{argmax}_t p(t|s)$$

▪ 전통적 기계 번역

- 입력 문장 $\rightarrow$ 단어나 구의 서열 또는 부분 트리의 집합으로 분할하여 번역 $\rightarrow$ 조각 번역된 것들 결합 $\rightarrow$ 확률이 가장 큰 것 선택

▪ 통계적 기계 번역

- 같은 내용을 표현하는 두 언어의 문장 쌍들을 많이 사용하여, 통계적으로 대응되는 단어, 구, 또는 문장을 찾아 번역

▪ 신경망 기계 번역

- 번역 자체를 딥러닝으로 수행

10. 음성 인식

❖ 음성 인식

- 음성 신호를 텍스트로 자동으로 변환하는 것
- 텍스트를 생산하는 주요 기술

❖ 전통적인 음성인식 시스템의 구성




그림 8.19 음성인식 시스템의 구성

음성 인식

❖ 특징 추출

- 음성 신호를 프레임으로 구분




그림 8.20 음성의 프레임 구분

- 프레임 별로 특징 추출
 - 음성 프레임 → MFCC 데이터

음성 인식

❖ 스펙트로그램(spectrogram)

- 음성 프레임들의 MFCC 데이터의 시각적 표현
- 딥러닝 모델을 음성 인식 등에 적용할 때 사용




그림 8.21 파형(a)과 스펙트로그램(b)

음성 인식

❖ 음향 모델(acoustic model)

- 대량의 학습용 음성 데이터베이스를 이용하여 음소(phoneme, 音素) 별로 특성 정보를 구성해 놓은 것




그림 8.22 음소 인식 HMM과 음소 상태 모델 GMM

음성 인식

❖ 언어 모델(language model)

- 대규모 텍스트 데이터로부터 이전에 나타난 단어열 정보로부터 현재 단어가 나타날 확률을 계산하는 모델
- 음성인식 단계에서 탐색 엔진이 가장 적절한 단어열을 찾을 수 있도록, 단어열의 확률을 계산할 때 사용

❖ 발음 사전(pronunciation lexicon)

- 단어별로 단어를 구성하는 글자인 문자소(grapheme,)와 음소로 응시켜 기록한 사전

음성 인식

❖ 탐색 엔진

- 주어진 MFCC 벡터 배열이 나타내는 단어 또는 문장을 효과적으로 탐색할 수 있도록, 음향 모델, 언어 모델, 발음사전을 결합한 자료구조 사용
- 가중 유한상태 변환기(weighted finite state transducer) 구조로 표현




그림 8.23 data와 dew를 인식하는 가중 유한 상태 변환기(weighted finite state transducer)

음성 인식

❖ 딥러닝 기반 음성 인식

- 음성인식 과정의 특정 단계에서 딥러닝 모델 사용




그림 8.24 딥러닝 신경망과 HMM을 이용한 음성인식 시스템의 구성

음성 인식

❖ 딥러닝 기반 음성 인식

- 딥러닝을 이용한 종단간 학습으로 음성인식




그림 8.25 종단간 학습 음성인식 시스템의 구성 [출처: Amodei 등 2016]