

Lecture 2: 신경망과 델타학습 (교재 Chapter 2 신경망)

<기계학습 개론> 2019 강의
서울대학교 컴퓨터공학부
장 병 탁

교재: 장교수의 딥러닝, 홍릉과학출판사, 2017.

Biointelligence Laboratory
School of Computer Science and Engineering
Seoul National University




목차

2.1 컴퓨터와 뇌 (교재 Ch 2.1)	3
2.2 퍼셉트론 구조 (교재 Ch 2.1)	5
2.3 델타 학습규칙 (교재 Ch 2.2)	9
2.4 참고 1: 최적화, LMS, Gradient Descent	20
2.5 참고 2: 무감독학습 SOM	22
요약	24

2.1 컴퓨터와 뇌 (교재 Ch 2.1) (1/2)

컴퓨터와 뇌의 비교




- 정확한 소자 (논리 소자)
- 소자 속도 매우 빠름 (10^{-9} 초)
- 디지털 회로망 (전자 회로망)
- 주소기반 메모리 (국지적/독립적)
- 논리/산술적 연산 (조작적)
- 중앙집중식 순차 처리
- 프로그래밍기반 명시적 지식



- 부정확한 소자 (10^{11} 개 뉴런)
- 소자 속도 느림 (10^{-3} 초)
- 아날로그 회로망 (10^{14} 개 연결선)
- 내용기반 메모리 (전역적/관계적)
- 패턴/연상기반 연산 (연관적)
- 분산적 병렬 처리
- 학습(경험/데이터)기반 암묵적 지식

2.1 컴퓨터와 뇌 (2/2)




인공 신경세포 (Artificial Neuron)

2.2 퍼셉트론 구조 (교재 Ch 2.1) (1/4)

■ 퍼셉트론 구조

- 가장 단순한 형태의 신경망 모델
- 생물학적 신경세포의 작동 방식을 수학적으로 모델링한 **인공 뉴런**
- 뇌의 구조를 모사한 정보처리 방식
 - 1958년 Rosenblatt가 학습이 가능함을 증명
- 인접한 두 뉴런의 연결부분인 **시냅스**에서 학습이 일어남
- 출력노드의 활성화값


$$S = \sum_{i=1}^n w_i x_i + w_0 = \sum_{i=0}^n w_i x_i = \mathbf{W} \cdot \mathbf{X}$$



- 임계논리 활성화 함수: 임계치를 넘으면 +1을, 넘지 않으면 -1을 출력
 - Rosenblatt의 퍼셉트론(단순 퍼셉트론)은 하나의 임계논리유닛으로 구성

2.1 퍼셉트론 구조 (2/4)

■ 단순 퍼셉트론의 작동 원리



2.2 퍼셉트론 구조 (3/4)

■ 퍼셉트론의 학습

- 학습 목표: 주어진 학습패턴들을 두 개의 클래스로 분류하는 **경계면 찾기**

$$f(s) = \begin{cases} +1 & \text{if } s > 0 \\ -1 & \text{otherwise} \end{cases}$$

- 학습 패턴 x 가 입력될 때 출력되는 f 를 계산, 목표 출력과 일치하지 않으면 변경
- 퍼셉트론 학습 규칙
 - 학습예를 반복적으로 관측하면서 가중치를 변경하면 선형 분리가 가능한 분류 문제의 경우 올바른 분류기를 학습할 수 있음

2.2 퍼셉트론 구조 (4/4)

■ 단순 퍼셉트론의 학습 원리

시작:

가중치 벡터 w 를 랜덤하게 생성

테스트:

벡터 $x \in P \cup N$ 를 랜덤하게 선택

$x \in P$ 이고 $w \cdot x > 0$ 이면 goto 테스트,

$x \in P$ 이고 $w \cdot x \leq 0$ 이면 goto 더하기,

$x \in N$ 이고 $w \cdot x < 0$ 이면 goto 테스트,

$x \in N$ 이고 $w \cdot x \geq 0$ 이면 goto 빼기.

더하기:

$w = w + x$ 로 설정, goto 테스트

빼기:

$w = w - x$ 로 설정, goto 테스트

선형 뉴런

초평면 방정식:

$$X \cdot W - \theta = 0$$

$\frac{W}{|W|}$ 초평면에 직교하는
단위 벡터

원점

$X \cdot W - \theta > 0$
초평면 위쪽

$X \cdot W - \theta < 0$
초평면 아래쪽

2.3 델타 학습규칙 (교재 Ch. 2.2) (1/11)

- 임계활성화함수(linear threshold unit, LTU)의 한계
 - +1 또는 -1의 이진값만을 출력
 - 오차는 0 아니면 2만 가능: 미세한 오차 조정 불가능
- 선형 활성화 함수(linear unit)
 - 임계활성화함수의 한계를 해결
 - 선형퍼셉트론(linear perceptron): 선형 활성화 함수를 사용하는 퍼셉트론
 - 델타 규칙을 사용하여 학습 가능 (Widrow & Hoff, 1960)

2.3 델타 학습규칙 (2/11)

■ 델타규칙에 의한 학습 알고리즘

- 학습 데이터 N 개

$$D_N = \{(\mathbf{x}^{(d)}, y^{(d)})\}_{d=1}^N$$

- 가중치 벡터 $\mathbf{w}$ 를 갖는 선형 유닛의 계산


$$f^{(d)} = f(\mathbf{x}^{(d)}; \mathbf{w}) = \sum_i w_i x_i^{(d)}$$

- 학습 데이터집합에 대한 오차 E

$$E_N = \sum_{d=1}^N E_d \quad E_d = \frac{1}{2} (y^{(d)} - f^{(d)})^2$$

2.3 델타 학습규칙 (3/11)

■ 선형퍼셉트론의 구조



2.3 델타 학습규칙 (4/11)

■ 델타규칙에 의한 학습 알고리즘(cont.)

- 오차를 줄여주는 방향으로 시냅스 가중치를 교정

참고:

$$w_i \leftarrow w_i + \Delta w_i$$

$$E_d = \frac{1}{2}(y^{(d)} - f^{(d)})^2$$

$$\Delta w_i = -\eta \frac{\partial E_d}{\partial w_i}$$

$$f^{(d)} = f(\mathbf{x}^{(d)}; \mathbf{w}) = \sum_i w_i x_i^{(d)}$$

오차를 가중치 w_i 에 대해서 미분

$$\begin{aligned} \frac{\partial E_d}{\partial w_i} &= \frac{\partial E_d}{\partial f^{(d)}} \frac{\partial f^{(d)}}{\partial w_i} = \frac{\partial}{\partial f^{(d)}} \frac{1}{2} (y^{(d)} - f^{(d)})^2 \frac{\partial f^{(d)}}{\partial w_i} \\ &= \frac{1}{2} (-2)(y^{(d)} - f^{(d)}) x_i^{(d)} = -(y^{(d)} - f^{(d)}) x_i^{(d)} \end{aligned}$$

2.3 델타 학습규칙 (5/11)

- 델타규칙에 의한 학습 알고리즘(cont.)
 - 오차를 줄여주는 방향으로 시냅스 가중치를 교정

$$w_i \leftarrow w_i + \Delta w_i$$

$$\Delta w_i = -\eta \frac{\partial E_d}{\partial w_i}$$

오차를 가중치 w_i 에 대해서 미분

$$\begin{aligned} \frac{\partial E_d}{\partial w_i} &= \frac{\partial E_d}{\partial f^{(d)}} \frac{\partial f^{(d)}}{\partial w_i} = \frac{\partial}{\partial f^{(d)}} \frac{1}{2} (y^{(d)} - f^{(d)})^2 \frac{\partial f^{(d)}}{\partial w_i} \\ &= \frac{1}{2} (-2)(y^{(d)} - f^{(d)}) x_i^{(d)} = -(y^{(d)} - f^{(d)}) x_i^{(d)} \end{aligned}$$

2.3 델타 학습규칙 (6/11)

- 델타규칙에 의한 학습 알고리즘(cont.)
 - i 번째 가중치의 학습식
 - $\eta \in (0,1)$ 은 학습률 (learning rate)

$$w_i \leftarrow w_i + \eta(y^{(d)} - f^{(d)})x_i^{(d)}$$

2.3 델타 학습규칙 (7/11)

■ 선형 퍼셉트론 학습을 위한 델타 규칙

선형퍼셉트론학습 (학습예 집합 D_N , η)


각 학습예는 $\langle \mathbf{x}, y \rangle$ 꼴의 쌍을 이루며 $\mathbf{x}$ 는 입력값 벡터, y 는 목표 출력값이다. η 는 학습률이다 (e.g., .05).

- 1) 각 w_i 를 크기가 작고 랜덤한 값으로 초기화
- 2) 종료 조건이 만족될 때까지 아래를 반복
 - A. 각 Δw_i 를 0으로 초기화
 - B. 학습예 집합 D_N 의 각 $\langle \mathbf{x}, y \rangle$ 에 대해 아래를 실행
 - i. 선형 유닛에 $\mathbf{x}$ 를 입력하고 출력 f 를 계산
 - ii. 각 선형 유닛 가중치 w_i 에 대해
$$\Delta w_i \leftarrow \Delta w_i + \eta(y - f)x_i$$
를 계산
 - iii. 각 선형 유닛 가중치 w_i 에 대해
$$w_i \leftarrow w_i + \Delta w_i$$
를 실행

2.3 델타 학습규칙 (8/11)


■ 시그모이드 함수 뉴런

- 선형퍼셉트론은 **선형 분리**가 가능한 패턴분류 문제만 해결 가능
- 복잡한 문제를 풀기 위해서는 **비선형 결정 경계**를 생성해야 함
- 미분이 가능하려면 연속함수 일 필요가 있음
- **시그모이드(sigmoid) 함수**: 비선형, 미분 가능한 연속함수



Sigmoid function is
Differentiable

$$\frac{df(x)}{dx} = f(x)(1 - f(x))$$



2.3 델타 학습규칙 (9/11)

■ 시그모이드 뉴런 신경망

- 가중치 입력 계산시 비선형의 시그모이드 전이 함수를 거쳐서 출력함 (Aizerman, Braverman, & Rozonoer, 1964)

$$s = \sum_{i=0}^n w_i x_i = \mathbf{w} \cdot \mathbf{x} \quad f = \sigma(s) = \frac{1}{1 + \exp(-s)}$$

- $[-\infty, +\infty]$ 의 입력 구간 s 에 대한 출력을 $[0, 1]$ 의 구간으로 변환해줌
- 미분 가능

$$\frac{\partial \sigma(s)}{\partial s} = \sigma(s)(1 - \sigma(s))$$

2.3 델타 학습규칙 (10/11)

■ 시그모이드 뉴런의 델타 규칙

- 시그모이드 유닛의 계산

$$s^{(d)} = \sum_i w_i x_i^{(d)} \quad f^{(d)} = f(\mathbf{x}^{(d)}; \mathbf{w}) = \frac{1}{1 + \exp(-s^{(d)})}$$

- 오차의 가중치에 대한 미분

$$\begin{aligned} \frac{\partial E_d}{\partial w_i} &= \frac{\partial E_d}{\partial f^{(d)}} \frac{\partial f^{(d)}}{\partial w_i} = \frac{\partial}{\partial f^{(d)}} \frac{1}{2} (y^{(d)} - f^{(d)})^2 \frac{\partial f^{(d)}}{\partial s^{(d)}} \frac{\partial s^{(d)}}{\partial w_i} \\ &= \frac{1}{2} (-2)(y^{(d)} - f^{(d)}) f^{(d)} (1 - f^{(d)}) x_i^{(d)} = -(y^{(d)} - f^{(d)}) f^{(d)} (1 - f^{(d)}) x_i^{(d)} \end{aligned}$$

2.3 델타 학습규칙 (11/11)


■ 시그모이드 뉴런의 델타 규칙(cont.)

- i 번째 가중치의 학습식
 - $\eta \in (0,1)$ 은 학습률 (learning rate)
- 시그모이드를 미분한 항 $f^{(d)}(1 - f^{(d)})$ 가 추가된 것 외에 동일함

$$w_i \leftarrow w_i + \eta(y^{(d)} - f^{(d)})f^{(d)}(1 - f^{(d)})x_i^{(d)}$$

2.4 참고 1: 최적화, LMS, Gradient Descent (1/2)

- Learning as an optimization problem
- Optimization
- Error minimization
- Gradient descent
- Error defined as mean square
- Least mean square (LMS) method



Error Landscape

Gradient

$$\nabla E[\vec{w}] \equiv \left[\frac{\partial E}{\partial w_0}, \frac{\partial E}{\partial w_1}, \dots, \frac{\partial E}{\partial w_n} \right]$$

Training rule:

$$\Delta \vec{w} = -\eta \nabla E[\vec{w}]$$

i.e.,

$$\Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$

2.4 참고 1: 최적화, LMS, Gradient Descent (2/2)

Delta rule for LMS

$$w_i \leftarrow w_i + \Delta w_i \quad , \quad \Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$



$$\Delta w_i = \eta \sum_{d \in D} (t_d - o_d) x_{id}$$

$$\begin{aligned} \frac{\partial E}{\partial w_i} &= \frac{\partial}{\partial w_i} \frac{1}{2} \sum_d (t_d - o_d)^2 \\ &= \frac{1}{2} \sum_d \frac{\partial}{\partial w_i} (t_d - o_d)^2 \\ &= \frac{1}{2} \sum_d 2(t_d - o_d) \frac{\partial}{\partial w_i} (t_d - o_d) \\ &= \sum_d (t_d - o_d) \frac{\partial}{\partial w_i} (t_d - \vec{w} \cdot \vec{x}_d) \\ \frac{\partial E}{\partial w_i} &= \sum_d (t_d - o_d) (-x_{i,d}) \end{aligned}$$

2.5 참고 2: 무감독학습 SOM (1/2)

Self-Organizing Map (SOM)

- Output nodes build a 2D lattice
- Winner-take-all
- Competitive learning
- Dimension reduction
- Clustering
- Visualization



$$m_i(t+1) = \begin{cases} m_i(t) + \alpha(t)[x(t) - m_i(t)] & \text{if } i \in N(t) \\ m_i(t) & \text{otherwise,} \end{cases}$$

2.5 참고 2: 무감독학습 SOM (2/2)



■ <https://www.youtube.com/watch?v=b3nG4c2NECI&t=35s>

■ https://www.youtube.com/watch?v=3YhiU2_uk5I

■ <https://www.youtube.com/watch?v=zyYZuAQZWTM>

■ <https://www.youtube.com/watch?v=IA6eGYMyr1A>

■ <https://www.youtube.com/watch?v=WIGxS-quGSo>
(Growing Neural Gas Algorithm)



요약

- 신경망은 뇌를 닮은 계산 모델로서 디지털컴퓨터와 달리 학습을 잘 하는 장점이 있다.
- 퍼셉트론은 다수의 입력뉴런과 하나의 출력 뉴런으로 구성된 단순한 신경망이다.
- 1958년의 초기 퍼셉트론은 임계논리함수를 사용하였으며 +1과 -1의 이진수만을 출력한다. 출력이 목표출력값과 틀릴 경우에만 학습이 일어난다.
- 1960년는 선형함수 뉴런으로 구성된 선형퍼셉트론과 그 학습 알고리즘인 델타규칙이 제안되었다. 선형퍼셉트론은 이진 소자가 아니고 선형소자여서 출력이 반응하는 미세한 차이에 대해서도 늘 학습한다. 단점은 선형분리 가능한 문제만 풀수 있다는 것이다.
- 후에 발견된 시그모이드 뉴런은 연속함수로 미분이 가능하면서도 비선형 함수인 장점이 있다.
- 델타 학습규칙은 감독학습의 핵심 원리를 모두 가지고 있는 아주 중요한 기본적인 학습 방식이다.
- 학습문제는 일반적으로 오류를 최소화하는 최적화 문제로 형식화 되며, 오류는 보통 평균 제곱오차로 정의된다. 오류 함수를 경사하강법을 써서 반복적으로 최소화한다. 이를 최소 평균제곱오차법(LMS)이라 한다.
- 무감독학습을 하는 신경망도 존재하며 자기조직신경망(SOM이 그 예이다.