

Lecture 6: 컨볼루션 신경망

(교재 Chapter 4 컨볼루션 신경망)

<기계학습 개론> 2019 강의
서울대학교 컴퓨터공학부
장 병 탁

교재: 장교수의 딥러닝, 홍릉과학출판사, 2017.

Biointelligence Laboratory
School of Computer Science and Engineering
Seoul National University



Version: 20170924/20191009



목차

6.1 컨볼루션 신경망	3
6.2 LeNet5	11
6.3 AlexNet	14
6.4 DeepFace	20
6.5 GoogLeNet	27
요약	31


6.1 컨볼루션 신경망 (1/8)

- 완전연결 다층신경망(MLP)의 문제점
 - 인접한 두 계층의 뉴런들 간에 완전 연결 구조(fully connected)
 - 이론적으로는 문제 해결이 가능하나 큰 영상의 경우 문제 복잡도가 매우 커짐
 - 이미지의 위치, 각도, 크기 변화 등에 취약
 - 별도의 특징 추출(feature extraction)이 필요
- 컨볼루션 신경망(Convolutional Neural Networks, CNN)의 해결책
 - 부분적인 수용영역을 갖는 컨볼루션 커널을 도입하여 복잡도를 감소시킴
 - 층을 쌓아가며 입력 영상의 정보를 재조합, 점진적으로 추상적인 특징지도를 학습
 - 서로 다른 위치에 있는 컨볼루션 커널들의 가중치를 공유(weight sharing)
 - 이미지의 위치, 각도, 크기 변화 등에 상대적으로 견고
 - 특징 추출과 분류의 두 단계를 하나로 통합

6.1 컨볼루션 신경망 (2/8)

■ 컨볼루션 신경망(CNN)의 구조

- 다수의 컨볼루션 층 (C)
- 다수의 서브샘플링 층 (S)
- 후반의 완전연결층 (F)



“A”자 문자 이미지를 인식하는 CNN의 구조(LeCon et al., 1998)


6.1 컨볼루션 신경망 (3/8)

■ CNN (Convolutional Neural Network)


- 입력 이미지에 컨볼루션 커널을 적용하여 특징맵(feature map) 생성

■ 컨볼루션 커널

- 특징을 추출하는 일종의 템플릿(template)
- 위치를 바꾸어가며 여러 번 반복적으로 적용
- 위치가 바뀌어도 연결 가중치는 공유(weight sharing)
- 위치에 무관한 특징 추출 & 학습할 전체 매개변수 수 감소




6.1 컨볼루션 신경망 (4/8)




Fully connected layer

All different weights



Locally connected layer

All different weights



Convolution layer

Shared weights


- 연결선(가중치) 종류의 수
 - 완전연결층: $5 \times 5 = 25$
 - 지역연결층: $2 + 3 + 3 + 2 = 13$
 - 컨볼루션층: 3 (같은 색은 같은 가중치)

6.1 컨볼루션 신경망 (5/8)

컨볼루션: 입력 이미지에서 특징맵까지

Convolution Layer

32x32x3 image



Filters always extend the full depth of the input volume

5x5x3 filter




Convolve the filter with the image
i.e. “slide over the image spatially,
computing dot products”

6.1 컨볼루션 신경망 (6/8)

컨볼루션: 입력 이미지에서 특징맵까지


Convolution Layer



6.1 컨볼루션 신경망 (7/8)

컨볼루션: 입력 이미지에서 특징맵까지

For example, if we had 6 5x5 filters, we'll get 6 separate activation maps:



We stack these up to get a “new image” of size 28x28x6!



6.1 컨볼루션 신경망 (8/8)

■ 서브샘플링

- 공간적 해상도를 줄여 줌
- 차원 축소
- 문제의 복잡도 감소
- 물체의 위치 및 각도 변화에 견고

■ 서브샘플링의 종류

- 최대풀링(max pooling)
 - 최대치를 취함
- 평균풀링(average pooling)
 - 평균치를 취함
- Min pooling
- L2-norm pooling
- ...



6.2 LeNet5 (1/3)

■ CNN의 예: LeNet5


- LeCun에 의해 고안됨(1998)

■ 구조

- 입력(Input) : 32x32 픽셀 이미지
- 컨볼루션 : 5x5 특징맵 사용
- 서브샘플링 : $\frac{1}{2}$ 로 축소
- 완전연결층 : 방사기저함수(RBF) 사용

■ 신경망층에 의한 크기 변화

- 입력 : 32 x 32
- C1 : 6 x 28 x 28
- S2 : 6 x 14 x 14
- C3 : 16 x 10 x 10
- S4 : 16 x 5 x 5
- C5 : 120
- F6 : 84
- 출력 : 10




6.2 LeNet5 (2/3)

■ 출력값 계산

$$y_j = \arg \min_i \sum_{i=1}^{84} (f_i - w_{ij})^2, \quad j = 0, 1, \dots, 9$$

- : 출력 영상 특징 값
- : 목표 영상 특징 값



$$Y_j = \sum_{i=1}^{84} (F_i - w_{ij})^2, \quad j = 0, \dots, 9$$

■ 모델 파라미터 수

- 전체 연결선 : 약 187,000 개
((28 x 28) x 236 x 10의 완전 연결)
- 실제 학습되는 가변 가중치 : 약 14,000 개
- 완전연결 다층신경망의 10% 이하



6.2 LeNet5 (3/3)

■ LeNet5의 활성화 함수

- 컨볼루션 층: 시그모이드 함수(sigmoidal function)
- 완전연결 층: 가우스분포 형태의 방사기저함수(radial basis function, RBF)

■ 정류선형유닛 (rectified linear unit, ReLU)

- 최근에 가장 많이 사용되는 활성화 함수
- 포화가 되지 않는(non-saturating) 비선형 구조
(cf. 시그모이드: 포화되는(saturating) 비선형 구조)
- 오차신호 희석 문제(vanishing gradient problem)을 완화, 빠른 수렴



6.3 AlexNet (1/6)

- 9층 딥러닝 구조 (Krizhevsky, Sutskever, & Hinton, 2012)
 - ILSVRC-2012 1위: 상위 5개(top-5 error) 테스트 에러율 15.3% (2위 : 26.2%)
 - 딥러닝이 기존의 컴퓨터 비전 기법의 성능을 월등히 능가한 최초 사례
 - GPU 사용
 - 후속 딥러닝 연구 촉발



6.3 AlexNet (2/6)

■ ImageNet Data

- 대규모 물체인식 콘테스트(ILSVRC) 에서 사용되는 대용량 데이터집합
- 카테고리 ~ 2만 2천 개, 이미지 ~ 1천 5백만 장
- 웹에서 수집한 이미지 + 아마존 미케니컬 터크(AMT) 크라우드소싱을 이용한 라벨링

■ ILSVRC(ImageNet Large-Scale Visual Recognition Challenge)

- PASCAL Visual Object Challenge의 일부
- 카테고리 = 1,000 개, 훈련 이미지 = 120만 장
검증 이미지 = 5만 장, 테스트 이미지 = 15만 장

쉬운 클래스




어려운 클래스




6.3 AlexNet (3/6)

- ImageNet 데이터 집합에 대한 매년 성능 향상



6.3 AlexNet (4/6)



- AlexNet의 구조
- 8개의 가중치 층 (5개의 컨볼루션층, 3개의 완전연결층)
 - 마지막 완전연결층(fully-connected, fc)의 출력 → 클래스에 대한 확률 분포를 생성하는 함수(소프트맥스)에 입력
 - 노드의 활성화 함수로 ReLU 사용
 - 다항분포 로지스틱 회귀 함수(logistic regression function)를 최대화하도록 학습
 - 제 1,2,5 컨볼루션층: w/ 서브샘플링, 제 3,4 컨볼루션층: w/o 서브샘플링

6.3 AlexNet (5/6)

- GPU 병렬처리
- GTX 580 GPU (3GB) x 2 사용
 - 단일 GPU로 120만장의 훈련 이미지 학습 불가능
- 전체 망을 각 GPU로 분산
 - 각 GPU는 각 층에서 절반의 커널을 수용
 - 1-2 / 3-4 / 4-5 층: 같은 GPU에 있는 커널맵에만 연결
 - 2-3 / 5-fc / fc-fc 층: 다른 GPU의 커널 맵까지 포함하여 연결



6.3 AlexNet (6/6)

■ 앙상블 학습(ensemble learning)


- 서로 다른 모델들의 예측을 결합함으로써 테스트 에러를 낮춤
- 딥러닝 모델은 학습 요구시간이 크기 때문에 앙상블 학습이 어려움

■ 드랍아웃(dropout)


- 뉴런의 출력을 일정 확률로 0으로 결정 : “제거된” 뉴런은 전파와 역전파 모두 참여하지 않음
- 매번 다른 구조를 샘플링 → 앙상블 학습과 비슷한 효과
- 공적응(co-adaptation) 제거 효과:
뉴런간의 의존도를 낮춤
- 테스트 시 (모든 뉴런의 출력 $\times 0.5$):
드랍아웃망들의 예측 분포의 기하 평균

■ AlexNet 적용

- 완전연결망에만 이용
- w/o 드랍아웃: 과다학습(overfitting) 현상 발생
- 수렴 시간은 통상의 2배



(a) Standard Neural Net



(b) After applying dropout.



6.4 DeepFace (1/7)

■ 기존의 머신러닝 알고리즘으로 시도

- SVM (support vector machines), PCA (principal component analysis), LDA (linear discriminant analysis)
- 학습 데이터의 수가 많을 때에는 학습이 잘 되지 않음

■ 컴퓨터 비전 분야의 시도


- 얼굴/물체 인식에서 다양한 디스크립터(기술자)를 찾는 연구
- 디스크립터는 사람이 미리 고안해야
- 영상의 모든 위치에 같은 연산자를 사용
- 최근에는 학습을 통해 디스크립터를 자동으로 추출하는 방법이 많이 이용
- 문제에 특화된 특징들을 학습을 통해 자동으로 추출할 수 있기 때문에 인식 문제에서 성능이 더 좋음



6.4 DeepFace (2/7)

■ 사진과 비디오 어디서든 쓸 수 있는 얼굴 인식 딥러닝 모델

- 페이스북에서 개발, 9층짜리 심층신경망을 사용하여 인간수준의 얼굴 인식 성능을 데모
- DeepFace는 일반 CNN과는 달리 노드들이 가중치를 공유하지 않음
- 이 신경망은 지역적으로 연결된 1억 2천만개의 노드와 매개변수로 구성.
- 심층망으로 학습한 특징벡터와 정확한 모델기반 정렬 알고리즘을 결합
- 최종 분류 단계에서 간단한 분류기를 사용하였음에도 불구하고 일반 환경에서 뛰어난 얼굴 인식 성능
- 심층망의 학습을 위하여 4천명의 사람에 대한 4백만장의 얼굴 영상이 학습 데이터로 사용
- 야외 환경에서 모은 얼굴 데이터셋인 LFW에 대해서 97.35%의 정확도.
- 이는 최신 얼굴 인식 성능을 27% 향상한 것이고 인간이 보이는 성능과 거의 유사.




Face Alignment

Representation (CNN)

6.4 DeepFace (3/7)

■ 전체 구조: 전처리 부


- 컨볼루션층 C1 $32 \times 11 \times 11 \times 3 @ 152 \times 152$, 2픽셀 간격 3×3 의 공간 이웃에 대해서 맥스풀링층 M2, C3
- C1 M2 C3 층의 목적은 모서리(edge)와 질감(texture)과 같은 저수준의 특징들을 추출.
- 대부분의 계산에 관여하지만 매개변수의 수는 적으며, 입력을 단순한 지역적 특징 집합으로 단지 확장.
- 맥스 풀링층은 CNN의 출력이 지역적인 변환에 덜 민감하도록 만드는 역할. 작은 등록 에러에 대해 견고.
- 그러나 많은 층의 풀링을 사용하면 구체적인 얼굴 구조와 정확한 위치에 대한 정보를 잃어버림



6.4 DeepFace (4/7)

■ 전체 구조: 매개변수 감소부, 지역층


- 세 개의 층(L4, L5, L6)은 지역적으로 연결. 앞 선 컨볼루션층처럼 이들은 필터뱅크를 적용.
- 특징맵의 모든 위치들이 서로 다른 필터 집합을 학습.
- 정합된 영상의 다른 지역이 다른 지역적 통계값을 가짐.
컨볼루션이 공간적 불변 가정은 성립하지 않음
- 특징 추출의 계산에는 부담을 주지 않지만 학습에 참여하는 매개변수의 수에는 영향을 줌.
- 가중치 공유없이 지역 연결층을 사용해도 되는 이유:
지역 연결층의 출력 유닛들 각각이 입력 영상의 아주 큰 패치에 의해 영향을 받는다는 가정하에 정당화



6.4 DeepFace (5/7)

■ 전체 구조: 완전 연결 부

- 눈과 입의 위치와 모양과 같이 얼굴 영상의 멀리 떨어진 부분에서 추출된 특징들 간의 상관관계를 찾음
- 첫번째의 완전 연결층(F7)의 출력은 얼굴표상 특징벡터로 사용
- 지역적인 디스크립터를 풀링하는 기존의 LBP 기반 표상과 대조적
- 마지막 완전연결층의 출력은 K개 클래스에 대한 소프트맥스에 입력되어 클래스 표지에 대한 분포를 출력 :



6.4 DeepFace (6/7)

■ 학습

- 학습의 목표는 올바른 클래스(얼굴 표지)의 확률을 최대화
- 학습 샘플 각각에 대한 교차 엔트로피 손실을 최소화함으로써 얻음
- K가 진짜 표지에 대한 인덱스일 때 손실은
- L의 매개변수에 대한 경사도를 계산, 확률적 경사도 강하(SGD) 사용하여 매개변수를 변경하여 최소화
- 경사도는 표준적인 오류역전파 알고리즘에 의해 계산.
- ReLU 활성화 함수 $\max(0, x)$ 를 사용
희소성(sparsity) - 평균적으로 최상위층에 있는 특징 요소들의 75%가 0의 값을 가짐
- 이 소프트역치 비선형함수는 매 컨볼루션 후에(국부연결층 및 완전연결층) 적용되며 여러 층을 거쳐 반복적으로 적용되는 과정에서 매우 비선형적이고 희소한(sparse) 특징을 생성
- 희소성은 드랍아웃(dropout)이라 불리는 정규화 방법을 사용하여 보장
- 딥페이스망의 경우 표상

$$G(I) = g^{\{F7\}}(g^{\{L6\}}(\dots (g^{\{G1\}}(T(I, \theta_T))) \dots))$$

6.4 DeepFace (7/7)

■ 학습 방법 및 결과

- 다중클래스 분류 문제, 오류역전파 알고리즘을 사용하여 확률적 경사도 강하법 (stochastic gradient descent, SGD) 으로 전방향 딥신경망을 학습
- 더 많은 수의 사람을 포함해도 에러는 크게 증가되지 않는 것으로 해석
- 더 큰 데이터셋을 사용함으로써 더욱 더 성능을 향상할 수 있음을 암시
- 아주 큰 얼굴 인식 데이터에 대해서는 깊은 신경망 구조가 필요

Network	Error	Network	Error	Network	Error
<i>DF-1.5K</i>	7.00%	<i>DF-10%</i>	20.7%	<i>DF-sub1</i>	11.2%
<i>DF-3.3K</i>	7.22%	<i>DF-20%</i>	15.1%	<i>DF-sub2</i>	12.6%
<i>DF-4.4K</i>	8.74%	<i>DF-50%</i>	10.9%	<i>DF-sub3</i>	13.5%

Table 1. Comparison of the classification errors on the *SFC* w.r.t. training dataset size and network depth. See Sec. 5.2 for details.

Network	Error (<i>SFC</i>)	Accuracy $\pm$ SE (<i>LFW</i>)
<i>DeepFace-align2D</i>	9.5%	0.9430 $\pm$ 0.0043
<i>DeepFace-gradient</i>	8.9%	0.9582 $\pm$ 0.0037
<i>DeepFace-Siamese</i>	NA	0.9617 $\pm$ 0.0038

Table 2. The performance of various individual *DeepFace* networks and the Siamese network.

Method	Accuracy $\pm$ SE	Protocol
Joint Bayesian [6]	0.9242 $\pm$ 0.0108	restricted
Tom-vs-Pete [4]	0.9330 $\pm$ 0.0128	restricted
High-dim LBP [7]	0.9517 $\pm$ 0.0113	restricted
TL Joint Bayesian [5]	0.9633 $\pm$ 0.0108	restricted
DeepFace-single	0.9592 $\pm$ 0.0029	unsupervised
DeepFace-single	0.9700 $\pm$ 0.0028	restricted
DeepFace-ensemble	0.9715 $\pm$ 0.0027	restricted
DeepFace-ensemble	0.9735 $\pm$ 0.0025	unrestricted
Human, cropped	0.9753	

Table 3. Comparison with the state-of-the-art on the *LFW* dataset.


Method	Accuracy (%)	AUC	EER
MBGS+SVM- [31]	78.9 $\pm$ 1.9	86.9	21.2
APEM+FUSION [22]	79.1 $\pm$ 1.5	86.6	21.4
STFRD+PMML [9]	79.5 $\pm$ 2.5	88.6	19.9
VSOFF+OSS [23]	79.7 $\pm$ 1.8	89.4	20.0
DeepFace-single	91.4 $\pm$ 1.1	96.3	8.6

Table 4. Comparison with the state-of-the-art on the *YTF* dataset.


6.5 GoogLeNet (1/4)

■ 더 깊게. 더 깊게. 하지만 너무 무겁지 않게.

- 22층짜리 컨볼루션 신경망으로 인셉션 모듈이라는 빌딩 블록을 반복적으로 사용
- 딥러닝은 층의 수와 각 층에 포함되는 노드의 수 성능. 하지만 노드 수 컴퓨팅 파워와 기억 용량. 과다학습의 위험.
- 인셉션 모듈(inception module)의 핵심 아이디어:
컨볼루션 신경망의 최적인 지역적 희소 구조를 찾아내고 이를 사용 가능한 자원으로 근사
- 이행 불변성(translation invariance)
- 필터의 크기를 1×1 , 3×3 , 5×5 의 세 가지로 제한.
- 각 단계에서 다른 병렬 풀링 경로를 더해주는 것이 유용.



인셉션 모듈



<https://leonardoaraujosantos.gitbooks.io/artificial-intelligence/content/googlenet.html>


6.5 GoogLeNet (2/4)

■ 문제점과 해결책: 인셉션 모듈


- 상위층으로 갈수록 고차의 추상적인 특징들을 추출되어 그 공간적인 밀집도가 줄어들기 때문에 컨볼루션 사이즈 축소
- 문제점: 아주 많은 수의 필터에 대해서 컨볼루션층을 구성할 때 비용이 많이 소모.
- 해결법: 임베딩(embedding)의 이점을 활용하여, 계산량이 크게 증가하게 되면 차원을 줄임

■ 구글넷 구조의 핵심:

- 상위층에서의 계산 복잡도를 줄이면서 각 층의 노드 수를 증가시킴. 큰 크기의 패치를 사용하여 계산량이 많은 컨볼루션을 하기 전에 차원 축소(1×1 컨볼루션)를 사용함으로써 이를 구현.
- 다양한 스케일 시각정보들의 특징들을 동시에 결합하는 것이 좋다는 실용적인 직관을 따름.
- 성능에 약간의 손해를 보면서 계산 비용을 줄이는 방법. 3~10배의 속도를 향상하면서도 유사한 성능을 달성.



인셉션 모듈



<https://leonardoraujosantos.gitbooks.io/artificial-intelligence/content/googlenet.html>

6.5 GoogLeNet (3/4)

■ 학습

- 보조 분류기: 인셉션 모듈의 출력 위에 작은 컨볼루션망을 추가하는 방식
 - 보조 분류기에서 계산되는 손실값이 구글넷 전체 손실값에 (0.3의 할인 가중치를 곱해서) 더해짐.
 - 추론시에는 이 보조망은 사용되지 않음.
- 추가망의 구체적인 구조
 - 필터크기와 간격의 평균 풀링 층을 사용하여 $4 \times 4 \times 512$ 의 (4a)층 출력과 $4 \times 4 \times 528$ 의 (4d) 염탐층(stag)
 - 1,024개의 정류선형유닛(ReLU) 뉴런으로 구성된 완전연결층
 - 70% 비율로 소거된 출력을 갖는 드롭아웃층
 - 소프트맥스 손실치를 갖는 선형층의 분류기(주분류기와 같은 1000개의 분류를 예측하나 추론시에는 사용 않음)
- 모델과 데이터 병렬성을 이용하는 DistBelief 분산 학습 시스템을 이용
- 비동기 확률적 경사도 강하 알고리즘을 사용
 - 0.9의 모멘텀 요소와 고정된 학습률 사용
 - 매 8번 학습 주기마다 4%씩 학습률을 줄임

<https://leonardoraujosantos.gitbooks.io/artificial-intelligence/content/googlenet.html>

6.5 GoogLeNet (4/4)

■ 데이터

- 알렉스넷(AlexNet)에 비해 12배 적은 수의 매개변수를 사용하면서도 더 높은 정확도를 획득
- 대회에서 구글넷은 독립적으로 7가지의 버전을 훈련시킨 후 이를 앙상블하여 결과를 예측
- 2012년의 SuperVision 방법에 비해서 성능을 상대적으로 56.5% 향상한 것이며, 2011년 우승팀인 Clarifai에 비해서 40% 상대적인 성능 향상을 이룸

Team	Year	Place	Error(top-5)	Uses external data
SuperVision	2012	1st	16.4%	no
SuperVision	2012	1st	15.3%	Imagenet 22K
Clarifai	2013	1st	11.7%	no
Clarifai	2013	1st	11.2%	Imagenet 22K
MSRA	2014	3rd	7.35%	no
VGG	2014	2nd	7.32%	no
GoogLeNet	2014	1st	6.67%	no

그림 4-12 GoogLeNet의 ILSVRC-2014 참가 성능

<https://leonardoaraujosantos.gitbooks.io/artificial-intelligence/content/googlenet.html>

요약

■ 컨볼루션 신경망

- 컨볼루션과 서브샘플링을 반복적으로 적용하는 깊은 신경망 구조
- 서로 다른 위치에 있는 컨볼루션 커널들의 가중치를 공유(weight sharing)
- 문제 특성에 맞는 여러 종류의 컨볼루션 커널을 설계해서 사용 가능
- 빠른 학습 속도와 우수한 일반화 능력

■ AlexNet

- 딥러닝이 기존의 컴퓨터 비전 기법의 성능을 월등히 능가한 사례
- GPU를 사용하여 딥러닝을 구현하였으며 후속 딥러닝 연구를 촉발함
- Dropout 기법을 사용하여 과적합 문제를 완화

■ DeepFace

- 얼굴 인식에 특화된 딥러닝 모델로 페이스북에서 개발함
- 분류 정확도가 기존의 머신러닝 및 컴퓨터 비전 분야의 연구보다 27% 향상되었으며, 이는 인간이 보이는 성능과 거의 유사

■ GoogLeNet

- 인셉션 모듈(inception module)을 도입하여 컨볼루션 신경망의 최적인 지역적 희소 구조를 찾아내고 이를 사용 가능한 자원으로 근사
- 알렉스넷(AlexNet)에 비해 12배 적은 수의 매개변수를 사용하면서도 더 높은 정확도를 획득함

문제

- 컨볼루션 신경망(CNN)이 영상 처리에 특히 성공적인 특성은 무엇인가?
- CNN 모델 설계시 도메인 지식을 반영할 수 있는 방법에는 어떤 것이 있는가?
- 컨볼루션 커널의 핵심 아이디어는 무엇인가? 장점과 단점은?
- 풀링의 종류와 각 방법의 장단점은 무엇인가?
- 커널의 종류 크기 갯수, 특징맵의 종류 크기 갯수, 스트라이드 크기, 컨볼루션 층과 풀링 층의 수가 상호간 그리고 전체 일반화 능력에 미치는 영향은 무엇인가?
- 실세계 문제 해결에 성공한 CNN 모델의 사례는 어떤 것이 있는가?
- 각 모델 사례에서 성공의 핵심 요인은 어디에 있다고 생각하는가?
- 각 모델의 특성을 Distributed Representation vs. Localist Representation의 Tradeoff 관점에서 분석하시오.
- 각 CNN 딥러닝 모델에서 다수의 층의 필요한 또는 유용한 이유는 무엇인가? 과적합 문제를 피하면서 층을 추가하는 방법은?