

Lecture 7: 딥빌리프넷 (교재 Chapter 5 딥빌리프넷)

<기계학습 개론> 2019 강의
서울대학교 컴퓨터공학부
장 병 탁

교재: 장교수의 딥러닝, 홍릉과학출판사, 2017.

Biointelligence Laboratory
School of Computer Science and Engineering
Seoul National University




목차

7.1 제한볼츠만머신(RBM)	3
7.2 대조다이버전스 학습	6
7.3 딥빌리프넷(DBN)	12
7.4 드랍아웃	19
7.5 응용 사례	22

7.1 제한볼프만머신(RBM) (1/3)

A stochastic machine consisting of stochastic neurons with symmetric synaptic connections.



Boltzmann machine (BM)

$\mathbf{x}$: state vector of BM

w_{ji} : synaptic connection from i to j

Structure (weights)

$$w_{ji} = w_{ij} \quad " \quad i, j$$

$$w_{ii} = 0 \quad " \quad i$$

Energy

$$E(\mathbf{x}) = - \frac{1}{2} \sum_i \sum_{j \neq i} w_{ji} x_i x_j$$

Probability

$$P(\mathbf{X} = \mathbf{x}) = \frac{1}{Z} \exp \left(- \frac{E(\mathbf{x})}{T} \right)$$

7.1 제한볼츠만머신(RBM) (2/3)

- 제한 볼츠만 머신(Restricted Boltzmann Machine, RBM)
 - 입력 뉴런층과 하나의 은닉 뉴런층으로 구성된 무감독 학습 신경망 모델

$$p(h_i | \mathbf{x}) = \frac{1}{1 + \exp(-\sum_i w_{ji} x_i)}$$




그림 5.1 제한 볼츠만 머신(RBM)의 구조

7.1 제한볼프만머신(RBM) (3/3)

■ 제한 볼프만 머신의 특징

- 입력 뉴런간에, 은닉 뉴런간에 연결선이 없다. 반면 원래의 볼프만 머신은 모든 뉴런들이 다른 모든 뉴런과 연결된 완전그래프 형태의 망구조를 가진다.
- 확률 모델이다. 반면 퍼셉트론은 결정적 모델이다.
- 제한 볼프만 머신의 상위층 뉴런은 감독학습 신호를 받지않으며, 입력 신호를 한 단계 변환하는 은닉 뉴런 역할을 한다. 이러한 모델은 통계에서 은닉 변수 모델(latent variable model)로도 알려져 있으며 마코프랜덤필드(Markov random field, MRF)와 같은 계열의 모델이다.

■ 제한 볼프만 머신 각 뉴런의 계산

- $P(\mathbf{x}|\mathbf{h}) = \prod_i P(x_i|\mathbf{h})$
- $P(x_i|\mathbf{h}) = \sigma(\sum_j w_{ji} h_j)$

7.2 대조다이버전스 학습 (1/6)

■ 볼츠만 머신의 학습

- 무감독 학습 과정이기 때문에 우도 $P(\mathbf{x})$ 를 최대화하도록 학습

$$P(\mathbf{x}) = \sum_{\mathbf{h}} \frac{1}{Z} \exp[-E(\mathbf{x}, \mathbf{h})] = \sum_{\mathbf{h}} \frac{\exp[-E(\mathbf{x}, \mathbf{h})]}{\sum_{\mathbf{h}'} \sum_{\mathbf{x}'} \exp[-E(\mathbf{x}', \mathbf{h}')]}$$

- $E(\mathbf{x}, \mathbf{h}) = -\sum_j \sum_i h_j w_{ji} x_i$
- w_{ji} : 번째 입력 뉴런과 번째 은닉 뉴런을 연결하는 연결선의 가중치
- 최대 우도값 또는 로그 우도값을 갖는 가중치 벡터를 찾는 문제

$$\mathbf{w}^* = \underset{\mathbf{w}}{\operatorname{argmax}} \log P(\mathbf{x}) = \underset{\mathbf{w}}{\operatorname{argmax}} L(X; \theta)$$

- 로그우도 추정법의 정의로부터 매개변수에 대한 미분값이 0으로 수렴해야 함

$$\frac{\partial L(X; \theta)}{\partial w_{ji}} \rightarrow 0$$

7.2 대조다이버전스 학습 (2/6)

- 대조 다이버전스(contrastive divergence) 방법
 - 두개의 확률분포 차이를 최소화함으로써 학습하는 방식

$$\begin{aligned}\frac{\partial L(X; \theta)}{\partial w_{ji}} &= \int P(\mathbf{x}, \theta) \frac{\partial \log f(\mathbf{x}; \theta)}{\partial \theta} d\mathbf{x} - \frac{1}{N} \sum_{d=1}^N \frac{\partial \log f(\mathbf{x}^{(d)}; \theta)}{\partial \theta} \\ &= \langle x_i h_j \rangle_{P(\mathbf{x}, \theta)} - \langle x_i h_j \rangle_X \\ &= \langle x_i h_j \rangle_{\infty} - \langle x_i h_j \rangle_0\end{aligned}$$

- $\langle f \rangle_P$: 분포 에 대한 의 기대치
- $\langle f \rangle_X$: 학습데이터 에 대한 기대치
- $\langle f \rangle_P - \langle f \rangle_X$: 두 기대치 차이
- $\langle x_i h_j \rangle_{\infty}$: 몬테칼로 시뮬레이션으로 두 기대치 차이를 추정한 것

7.2 대조다이버전스 학습 (3/6)

■ 제한 볼츠만 머신


- 무한번 반복해야 계산되는 $\langle x_i h_j \rangle_\infty$ 를 한 번의 몬테칼로 시뮬레이션으로 대체하여 추정

$$\langle x_i h_j \rangle_\infty - \langle x_i h_j \rangle_0 \approx \langle x_i h_j \rangle_1 - \langle x_i h_j \rangle_0$$

- 따라서 학습식은 다음과 같이 주어진다.

$$w_{ji} \leftarrow w_{ji} + \Delta w_{ji}$$

$$\Delta w_{ji} = -\eta \frac{\partial L(X; \theta)}{\partial w_{ji}} = -\eta (\langle x_i h_j \rangle_0 - \langle x_i h_j \rangle_1)$$



$$\Delta w_{ji} = \eta (\langle x_i h_j \rangle_0 - \langle x_i h_j \rangle_\infty)$$

$$\Delta w_{ji} \approx \eta (\langle x_i h_j \rangle_0 - \langle x_i h_j \rangle_1)$$

그림 5.2 제한 볼츠만 머신의 학습

7.2 대조다이버전스 학습 (4/6)

■ 제한 볼츠만 머신 학습 알고리즘

1. 은닉 뉴런의 수 n 를 정하고 가중치를 초기화한다.
2. 관측 뉴런에 학습 벡터 x 를 입력한다.
3. For $j = 1$ to H
 $P(h_j|x)$ 을 계산
4. 위의 3을 여러 번 반복한다.
5. 모든 i, j 쌍에 대해서 x_i 와 h_j 가 동시에 on이 되는 수를 계산해서 $\langle x_i h_j \rangle_0$ 라 한다.
6. For $i = 1$ to H
 $P(x_i|h)$ 을 계산
7. 위의 6을 여러 번 반복한다.
8. For $j = 1$ to H
 $P(h_j|x)$ 을 계산 // 6의 결과를 이용하여
9. 위의 8을 여러 번 반복한다.
10. 모든 i, j 쌍에 대해서 x_i 와 h_j 가 동시에 on이 되는 수를 계산해서 $\langle x_i h_j \rangle_1$ 라 한다.
11. 모든 i, j 쌍에 대해서 가중치를 다음과 같이 변경 한다.

$$\Delta w_{ji} = \eta(\langle x_i h_j \rangle_0 - \langle x_i h_j \rangle_1)$$

7.2 대조다이버전스 학습 (5/6)

■ 응용 예: 패턴 생성




그림 5.3 제한 볼츠만 머신에 의한 필기체 숫자 학습 방법

7.2 대조다이버전스 학습 (6/6)

■ 응용 예: 패턴 생성



2에 대해 학습시켰던 모델로부터 2를 입력으로 하여 얻은 새로운 이미지



2의 이미지로 학습하고 3의 이미지를 입력했을 때 생성되는 이미지

그림 5.4 RBM을 이용한 문자 생성 실험(Hinton, NIPS 2007 Tutorial on Deep Belief Nets)

7.3 딥빌리프넷(DBN) (1/7)

■ 딥빌리프넷(deep belief network, DBN)

- 제한 볼츠만 머신을 빌딩블록으로하여 여러 층을 쌓은 딥러닝 아키텍처

■ 특징

- 층을 깊게 쌓은 신경망을 학습하는 데 있어서 널리 알려진 오차 신호 희석 (vanishing gradient) 문제가 있다.
- 오차 신호 희석 문제를 해결하기 위해 아래층(입력에 가까운 층)에서부터 위층으로 가면서 순차적으로 선훈련을 진행한다. 이 기술을 층별 선훈련(layerwise pre-training)이라고 한다.
- 입력과 같은 출력을 재생성하는 오토인코더 또는 분류기로 사용할 수 있다.

7.3 딥빌리프넷(DBN) (2/7)

■ 층별 선훈련 방법




그림 5.5 층별 선훈련 방법

7.3 딥빌리프넷(DBN) (3/7)

■ 딥빌리프넷 오토인코더와 분류기




그림 5.6 딥빌리프넷 오토인코더




그림 5.7 딥빌리프넷 분류기

7.3 딥빌리프넷(DBN) (4/7)

■ 딥빌리프넷의 확률식

- 일반적인 딥빌리프넷이 관측가능한 입력 벡터를 $\mathbf{x}$ 와 l 개의 은닉층을 가지며, 이때 k 번째 층의 값을 $\mathbf{h}^k$ 라고 하자. 이렇게 딥네트워크 구조가 결정된 딥빌리프넷은 다음과 같은 결합확률 분포를 갖는 확률 그래프 모델로 정의 된다.

$$P(\mathbf{x}, \mathbf{h}^1, \dots, \mathbf{h}^l) = \left(P(\mathbf{x} | \mathbf{h}^1) \prod_{k=1}^{l-2} P(\mathbf{h}^k | \mathbf{h}^{k+1}) \right) P(\mathbf{h}^{l-1}, \mathbf{h}^l)$$

- $\mathbf{h}^{l-1}$ 과 $\mathbf{h}^l$ 의 관계는 조건부 확률이 아님을 유의하자.
- 계층별 관계를 나타내는 조건부 확률 및 결합 확률(최상단의 두 층)은 RBM을 이용한 층별 선훈련을 통해 얻는다.
- 이와 같이 계층별 관계 및 네트워크를 확률을 이용해 표현할 경우, 학습 데이터에 포함되지 않은 패턴도 샘플링을 통해 생성할 수 있다는 장점을 갖는다.

7.3 딥빌리프넷(DBN) (5/7)

■ 영상 데이터에 대한 딥빌리프넷의 학습과정 개요

1. 영상의 픽셀값들을 입력 벡터로 사용하여 층별 선훈련을 통해 첫 번째 층을 학습한 후, 은닉층의 출력 벡터를 구한다.
2. 하위 은닉층의 출력 벡터를 입력 벡터로 취급하여 다음 계층을 학습한다.
3. 2의 과정을 딥네트워크 구조에 따라 상위 층으로 올라가면서 반복한다.
4. (오토인코더 학습의 경우) Wake-Sleep 알고리즘을 통해 미세조정을 수행한다.
(분류기 학습의 경우) 오류역전파 알고리즘을 통해 미세조정을 수행한다.

7.3 딥빌리프넷(DBN) (6/7)

■ 응용 예: 필기체 숫자 인식문제와 생성문제




그림 5.9 필기체 숫자 인식 및 생성을 위한 딥빌리프넷 구조

표 5-1 MNIST 데이터에 대한 에러율 비교

방법	에러율
RBM 기반 생성 모델	1.25%
지지벡터머신	1.4%
오류역전파(1000 은닉 뉴런)	~1.6%
오류역전파(500 → 300 은닉 뉴런)	~1.6%
K-Nearest Neighbor	~3.3%

7.3 딥빌리프넷(DBN) (7/7)

■ 응용 예: 필기체 숫자 인식문제와 생성문제



그림 5.10 딥빌리프넷이 생성한 필기체 숫자 이미지





그림 5.11 테스트 데이터에서 딥빌리프넷을 통해 옳게 인식된 필기체 숫자 이미지의 예


7.4 드랍아웃 (1/3)

■ 드랍아웃(dropout)

- 딥네트워크를 학습하는 데에 있어 은닉층 안의 일부 노드를 강제로 꺼버리는 과정을 통해 분류 성능을 크게 향상시키는 트릭(Srivastava et al., 2014).
- ImageNet에 딥러닝을 성공적으로 적용했던 사례인 AlexNet에서도 사용됨



(a) Standard Neural Net



(b) After applying dropout.

7.4 드랍아웃 (2/3)

■ 드랍아웃의 적용과 효과

- 매 학습 데이터 하나마다 각 각 은닉 뉴런 별로 일정 확률(예를 들면 0.5)로 강제로 꺼질 뉴런을 무작위로 선택
- 이러한 과정을 통해, 만약 H 개의 은닉 뉴런을 가지고 있었다면, 마치 2^H 개의 다른 네트워크를 가지고 앙상블을 만든 효과를 갖게 됨
- 앙상블의 모든 네트워크의 가중치는 공유되어 강력한 정규화 효과를 지니게 됨
- 여러개의 모델을 한번에 다루는 효과를 부여하게 되어 훨씬 설명력이 좋은 다수의 모델을 학습

7.4 드랍아웃 (3/3)

■ 드랍아웃을 수행한 모델의 추론

- 다수의 모델의 결과를 합쳐서 이용하는 효과를 가지므로, 가중치의 값들을 반으로 줄여서 연산을 수행하면 된다. 이 과정은 출력들의 기하평균을 취하여 다음 계층으로 보내는 것과 동일한 효과를 낸다.

■ 은닉 층이 여러 개일 경우의 드랍아웃

- 매 은닉층마다 0.5 드랍아웃을 사용하는 것이 좋다.

■ 입력 계층의 드랍아웃

- 입력 계층에도 드랍아웃 사용하는 것이 좋다고 알려져 있다.

■ 딥빌리프넷에서의 드랍아웃

- 미세조정과정에서 감독 학습을 할 때 적용할 수 있다.

7.5 응용 사례 (1/5)

얼굴 방향 인식 문제




그림 5.12 얼굴 방향 인식 문제의 학습 및 테스트 데이터
(Hinton, NIPS 2007 Tutorial on Deep Belief Nets)

7.5 응용 사례 (2/5)




그림 5.13 얼굴 방향 인식 문제의 딥빌리프넷 구조

7.5 응용 사례 (3/5)

	GP on the pixels	GP on top-level features	GP on top-level features with fine-tuning
100 labels	22.2	17.9	15.2
500 labels	17.2	12.7	7.2
1000 labels	16.3	11.2	6.4

그림 5.14 얼굴방향인식 성능 비교






그림 5.15 얼굴 재생성 결과 및 층별 특징 추출 결과

7.5 응용 사례 (4/5)

Hinton & Salakhutdinov, 2006



7.5 응용 사례 (5/5)

Hinton & Salakhutdinov, 2006




그림 5.16 딥빌리프넷에서 얻은 코드를 이용한 문서 검색 성능 (Hinton, NIPS 2007 Tutorial on Deep Belief Nets)




그림 5.17 딥빌리프넷을 이용하여 문서에 코드부여한 후 도시한 결과 (Hinton & Salakhutdinov, 2006)

요약

■ RBM의 구조

- 입력 뉴런층과 하나의 은닉 뉴런층으로 구성된 무감독 학습 신경망 모델

■ RBM의 학습

- 무감독 학습 과정이기 때문에 우도 $P(\mathbf{x})$ 를 최대화하도록 학습
- 최대 우도값 또는 로그 우도값을 갖는 가중치 벡터를 찾는 문제로 대조 다이버전스를 이용

■ 딥빌리프넷

- 제한 볼츠만 머신을 빌딩블록으로하여 여러 층을 쌓은 딥러닝 아키텍처
- 층별 선훈련 방법을 이용
- 응용 예: 필기체 숫자 인식문제와 생성문제
- 드랍아웃

■ 응용 사례

- 얼굴 방향 인식 문제
- 문서의 코드화