

Lecture 9: 순환신경망 (교재 Chapter 7 순환신경망)

<기계학습 개론> 2019 강의
서울대학교 컴퓨터공학부
장 병 탁

교재: 장교수의 딥러닝, 홍릉과학출판사, 2017.

Biointelligence Laboratory
School of Computer Science and Engineering
Seoul National University



목차

7.1 순환신경망(RNN)의 구조	3
7.2 순환신경망의 학습	12
7.3 장단기 메모리망(LSTM)	32
7.4 장단기 메모리망의 변형과 확장	37
7.5 순환신경망의 활용	39
요약	43

7.1 순환신경망(RNN)의 구조 (1/9)

■ 정적인 입출력 사상(static input-output mapping)

$$f_t = f(\mathbf{x}_t; \mathbf{w})$$

- 출력과 같은 시간의 입력만 고려하는 모델

■ 동적인 입출력 사상(dynamic input-output mapping)

$$f_t = f(\mathbf{x}_t, \mathbf{x}_{t-1}, \dots, \mathbf{x}_1; \mathbf{w})$$

- 이전의 모든 시간의 입력을 고려하는 모델
- 순환신경망(Rumelhart et al. 1986)이 여기에 해당




그림 2.8 다층퍼셉트론 신경망(MLP)
정적인 입출력 사상




그림 7.2 순환신경망의 시간적 펼침
동적인 입출력 사상

7.1 순환신경망(RNN)의 구조 (2/9)




그림 7.1 순환신경망의 구조 (시간 t)

이 그림은 전형적인 순환신경망 구조를 보여준다. 이는 다층퍼셉트론의 변형으로서 은닉 뉴런층만이 재귀적인 구조를 갖는다. 이 구조는 $t-1$ 시간에서의 은닉 뉴런 활성화값들 $\mathbf{h}_{t-1}$ 이 t 시간에 복제되어 계속 과거의 정보를 축적하여 나가는 모델이다.

7.1 순환신경망(RNN)의 구조 (3/9)




그림 7.2 순환신경망의 시간적 펼침

이 그림은 전형적인 순환신경망 구조를 보여준다. 이는 다층퍼셉트론의 변형으로서 은닉 뉴런층만이 재귀적인 구조를 갖는다. 이 구조는 $t-1$ 시간에서의 은닉 뉴런 활성화값들 $\mathbf{h}_{t-1}$ 이 t 시간에 복제되어 계속 과거의 정보를 축적하여 나가는 모델이다.

7.1 순환신경망(RNN)의 구조 (4/9)

기본 순환신경망의 구조

$$\begin{aligned} \mathbf{U} &\in \mathbb{R}^{N_h \times N_x}, & \mathbf{x}_t &\in \mathbb{R}^{N_x}, \\ \mathbf{W} &\in \mathbb{R}^{N_h \times N_h}, & \mathbf{h}_t &\in \mathbb{R}^{N_h} \\ \mathbf{b} &\in \mathbb{R}^{N_h}, & \mathbf{V} &\in \mathbb{R}^{N_h} \\ \mathbf{y}_t, \mathbf{f}_t &\in \mathbb{R}^{N_y} \\ \phi &\in \{ReLU, \tanh, \text{sigmoid}, \dots\} \\ f &\in \{\text{softmax}, \text{sigmoid}, \dots\} \end{aligned}$$

- 데이터셋: $\{(\mathbf{x}_t, \mathbf{y}_t)\}_{t=1}^T$
- 입력 층: $\mathbf{x}_t$
- 은닉 층: $\mathbf{h}_t = \phi(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b})$
- 출력 층: $\mathbf{f}_t = f(\mathbf{V}\mathbf{h}_t + \mathbf{c})$




그림 7.2 순환신경망의 시간적 펼침

7.1 순환신경망(RNN)의 구조 (5/9)

기본 순환신경망의 구조

$$\begin{aligned} \mathbf{U} &\in \mathbb{R}^{N_h \times N_x}, & \mathbf{x}_t &\in \mathbb{R}^{N_x}, \\ \mathbf{W} &\in \mathbb{R}^{N_h \times N_h}, & \mathbf{h}_t &\in \mathbb{R}^{N_h} \\ \mathbf{b} &\in \mathbb{R}^{N_h}, & \mathbf{V} &\in \mathbb{R}^{N_h} \\ \mathbf{y}_t, \mathbf{f}_t &\in \mathbb{R}^{N_y} \\ \phi &\in \{ReLU, \tanh, \text{sigmoid}, \dots\} \\ f &\in \{\text{softmax}, \text{sigmoid}, \dots\} \end{aligned}$$

- 데이터셋: $\{(\mathbf{x}_t, \mathbf{y}_t)\}_{t=1}^T$
- 입력 층: $\mathbf{x}_t$
- 은닉 층: $\mathbf{h}_t = \phi(\mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b})$
- 출력 층: $\mathbf{f}_t = f(\mathbf{V}\mathbf{h}_t + \mathbf{c})$




그림 7.3 (a) 다층 순환신경망

7.1 순환신경망(RNN)의 구조 (6/9)

■ 기본 순환신경망의 구조 확장

■ 확장1: 다층 구조로 확장

- 순환신경망의 은닉층을 여러 층 쌓은 다층 순환신경망 모델은 은닉 층의 표현력을 확장하고 모델의 성능을 높이는 것으로 알려져 있다(Hihi & Bengio, 1995)(Graves, 2013).

■ 층의 수가 늘어나면 생기는 문제

- 문제: 학습 속도가 느려짐. 오류 역전파 과정에서 미분값의 급격한 증가 또는 급격한 감소 문제가 발생.
- 해결: 잔차 연결(residual connection)을 추가 (Neubig, 2017).

■ 확장1-2: 다층 구조로 확장. 잔차 연결(residual connection)을 추가

- 이전 층의 입력값을 현재 층 순환신경망 노드의 출력값에 더하여 다음 층으로 전달

$$\mathbf{h}_{1,t} = \phi_1(\mathbf{x}_t, \mathbf{h}_{1,t-1})$$

$$\mathbf{h}_{2,t} = \phi_2(\mathbf{h}_{1,t}, \mathbf{h}_{2,t-1}) + \mathbf{x}_t$$

$$\mathbf{h}_{3,t} = \phi_3(\mathbf{h}_{2,t}, \mathbf{h}_{3,t-1}) + \mathbf{h}_{1,t}$$

$$\mathbf{h}_{4,t} = \phi_4(\mathbf{h}_{3,t}, \mathbf{h}_{4,t-1}) + \mathbf{h}_{2,t}$$

7.1 순환신경망(RNN)의 구조 (7/9)




그림 7.3 (a) 잔차(residual) 연결이 추가된 다층 순환신경망

7.1 순환신경망(RNN)의 구조 (8/9)

■ 기본 순환신경망의 구조 확장

■ 확장2: 양방향(bidirectional) 구조로 확장

- 순서 데이터를 모델링할 때, 현재 순서 데이터 f_t 가 전 데이터 $\{\mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots\}$ 뿐만 아니라 후 데이터 $\{\mathbf{x}_{t+1}, \mathbf{x}_{t+2}, \dots\}$ 에 영향을 받을 수 있다.
 - 예: 음성인식, 필기체 문장 인식
- 양방향 구조의 순환신경망은 전 데이터 $\{\mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots\}$ 와 후 데이터 $\{\mathbf{x}_{t+1}, \mathbf{x}_{t+2}, \dots\}$ 그리고 현재 데이터 $\mathbf{x}_t$ 를 모두 참조한다.
 - 단방향 구조의 순환신경망은 $\{\mathbf{x}_{t-1}, \mathbf{x}_{t-2}, \dots\}$ 와 $\mathbf{x}_t$ 까지만 참조한다.

$$\mathbf{h}_t^f = \phi(\mathbf{U}^f \mathbf{x}_t + \mathbf{W}^f \mathbf{h}_{t-1}^f + \mathbf{b}^f)$$

$$\mathbf{h}_t^b = \phi(\mathbf{U}^b \mathbf{x}_t + \mathbf{W}^b \mathbf{h}_{t-1}^b + \mathbf{b}^b)$$

$$\mathbf{f}_t = f(\mathbf{V}^f \mathbf{h}_t^f + \mathbf{V}^b \mathbf{h}_t^b + \mathbf{c})$$

7.1 순환신경망(RNN)의 구조 (9/9)




그림 7.3 (a) 잔차(residual) 연결이 추가된 다층 순환신경망

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

- 출력에서 입력 방향뿐만 아니라, 시간축을 거슬러 올라가는 방향의 역전파를 함께 반영하여 경사 하강법(gradient descent)을 이용한 오류 역전파 알고리즘

■ 학습의 목표

- $\operatorname{argmin}_{\mathbf{U}, \mathbf{V}, \mathbf{W}}(L)$
- 각 시간별 출력 확률에 대한 음의 로그 우도(negative log-likelihood) L_t 를 최소화. 아래 손실 함수를 최소화시키면 그 목표를 달성할 수 있다.
- 경사 하강법을 위한 계산 대상: $\frac{\partial L}{\partial \mathbf{U}}, \frac{\partial L}{\partial \mathbf{V}}, \frac{\partial L}{\partial \mathbf{W}}$

■ 손실 함수

- $$L(\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T\}, \{\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T\})$$
$$= \sum_{t=1}^T L_t = - \sum_{t=1}^T \log(p_{\text{model}}(\mathbf{y}_t | \{\mathbf{x}_1, \dots, \mathbf{x}_t\}))$$

- 각 시간 t 의 손실함수의 합

■ 시간펼침 오류 역전파의 계산


- 계산복잡도, 공간복잡도 = $O(T)$
- 경사도 계산의 재귀성으로 인해 병렬화가 힘들다.
- 모든 매개변수에 대한 경사도 계산식과 유도 과정은 (Goodfellow et al., 2016)의 10.2.2절을 참고

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

■ 다변수 연쇄법칙 (multivariable chain rule)

- 예1: $z = z(x, y), x = x(t), y = y(t)$ 일 때, $\frac{\partial z}{\partial t} = ?$
- z 가 t 에 따라 변하는 의존 경로를 모두 찾아 각각 연쇄법칙을 적용해 더한다.
- $\frac{\partial z}{\partial t} = \frac{\partial z}{\partial x} \frac{\partial x}{\partial t} + \frac{\partial z}{\partial y} \frac{\partial y}{\partial t}$



7.2 순환신경망의 학습


■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

■ 다변수 연쇄법칙 (multivariable chain rule)

■ 예2: $z = z(f, h, t), f = f(x, t), x = y(y, t)$ 일 때, $\frac{\partial z}{\partial t} = ?$

■ z 가 t 에 따라 변하는 의존 경로를 모두 찾아 각각 연쇄법칙을 적용해 더한다.

$$\frac{\partial z}{\partial t} = \frac{\partial z}{\partial t} + \frac{\partial z}{\partial f} \frac{\partial f}{\partial t} + \frac{\partial z}{\partial f} \frac{\partial f}{\partial x} \frac{\partial x}{\partial t}$$



7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

■ 입력 층

- $\mathbf{x}_t$

■ 은닉 층


- $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$

- $\mathbf{h}_t = \phi(\mathbf{a}_t)$

■ 출력 층

- $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$


- $\mathbf{f}_t = f(\mathbf{o}_t)$



7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{V}} = \frac{\partial}{\partial \mathbf{V}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{V}}$$



입력 층
 $\mathbf{x}_t$
 은닉 층
 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$
 $\mathbf{h}_t = \phi(\mathbf{a}_t)$


출력 층
 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
 $\mathbf{f}_t = f(\mathbf{o}_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{V}} = \frac{\partial}{\partial \mathbf{V}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{V}}$$

$$\frac{\partial L_1}{\partial \mathbf{V}} = \frac{\partial L_1}{\partial \mathbf{f}_1} \frac{\partial \mathbf{f}_1}{\partial \mathbf{o}_1} \frac{\partial \mathbf{o}_1}{\partial \mathbf{V}}$$



입력 층
 $\mathbf{x}_t$
 은닉 층
 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$
 $\mathbf{h}_t = \phi(\mathbf{a}_t)$


출력 층
 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
 $\mathbf{f}_t = f(\mathbf{o}_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{V}} = \frac{\partial}{\partial \mathbf{V}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{V}}$$

$$\frac{\partial L_2}{\partial \mathbf{V}} = \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{V}}$$



입력 층
 $\mathbf{x}_t$
 은닉 층
 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$
 $\mathbf{h}_t = \phi(\mathbf{a}_t)$


출력 층
 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
 $\mathbf{f}_t = f(\mathbf{o}_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{V}} = \frac{\partial}{\partial \mathbf{V}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{V}}$$


$$\frac{\partial L_3}{\partial \mathbf{V}} = \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{V}}$$



7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

- $\frac{\partial L_1}{\partial \mathbf{V}} = \frac{\partial L_1}{\partial \mathbf{f}_1} \frac{\partial \mathbf{f}_1}{\partial \mathbf{o}_1} \frac{\partial \mathbf{o}_1}{\partial \mathbf{V}}$
- $\frac{\partial L_2}{\partial \mathbf{V}} = \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{V}}$
- $\frac{\partial L_3}{\partial \mathbf{V}} = \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{V}}$
- $\frac{\partial L}{\partial \mathbf{V}} = \frac{\partial}{\partial \mathbf{V}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{V}}$
- $\frac{\partial L}{\partial \mathbf{V}}$ solved!




입력 층 $\mathbf{x}_t$ 은닉 층 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$ $\mathbf{h}_t = \phi(\mathbf{a}_t)$	출력 층 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$ $\mathbf{f}_t = f(\mathbf{o}_t)$
--	--

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial}{\partial \mathbf{W}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{W}}$$




입력 층 $\mathbf{x}_t$	출력 층 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
은닉 층 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$	$\mathbf{f}_t = f(\mathbf{o}_t)$
$\mathbf{h}_t = \phi(\mathbf{a}_t)$	

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial}{\partial \mathbf{W}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{W}}$$

$$\frac{\partial L_1}{\partial \mathbf{W}} = \frac{\partial L_1}{\partial \mathbf{f}_1} \frac{\partial \mathbf{f}_1}{\partial \mathbf{o}_1} \frac{\partial \mathbf{o}_1}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{W}}$$



입력 층
 $\mathbf{x}_t$
 은닉 층
 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$
 $\mathbf{h}_t = \phi(\mathbf{a}_t)$


출력 층
 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
 $\mathbf{f}_t = f(\mathbf{o}_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial}{\partial \mathbf{W}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{W}}$$

$$\begin{aligned} \frac{\partial L_2}{\partial \mathbf{W}} &= \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{W}} \\ &+ \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{W}} \\ &= \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \left(\frac{\partial \mathbf{a}_2}{\partial \mathbf{W}} + \frac{\partial \mathbf{a}_2}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{W}} \right) \end{aligned}$$



입력 층
 $\mathbf{x}_t$
 은닉 층
 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$
 $\mathbf{h}_t = \phi(\mathbf{a}_t)$


출력 층
 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
 $\mathbf{f}_t = f(\mathbf{o}_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{W}} = \frac{\partial}{\partial \mathbf{W}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{W}}$$


$$\begin{aligned} \frac{\partial L_3}{\partial \mathbf{W}} &= \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{a}_3}{\partial \mathbf{W}} \\ &+ \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{a}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{W}} \\ &+ \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{W}} \\ &= \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \left(\frac{\partial \mathbf{a}_3}{\partial \mathbf{W}} + \frac{\partial \mathbf{a}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{W}} \right. \\ &\quad \left. + \frac{\partial \mathbf{a}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{W}} \right) \end{aligned}$$



7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

- $\frac{\partial L_1}{\partial W} = \frac{\partial L_1}{\partial f_1} \frac{\partial f_1}{\partial o_1} \frac{\partial o_1}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial W}$
- $\frac{\partial L_2}{\partial W} = \frac{\partial L_2}{\partial f_2} \frac{\partial f_2}{\partial o_2} \frac{\partial o_2}{\partial h_2} \frac{\partial h_2}{\partial a_2} \left(\frac{\partial a_2}{\partial W} + \frac{\partial a_2}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial W} \right)$
- $\frac{\partial L_3}{\partial W} = \frac{\partial L_3}{\partial f_3} \frac{\partial f_3}{\partial o_3} \frac{\partial o_3}{\partial h_3} \frac{\partial h_3}{\partial a_3} \left(\frac{\partial a_3}{\partial W} + \frac{\partial a_3}{\partial h_2} \frac{\partial h_2}{\partial a_2} \frac{\partial a_2}{\partial W} + \frac{\partial a_3}{\partial h_2} \frac{\partial h_2}{\partial a_2} \frac{\partial a_2}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial W} \right)$
- $\frac{\partial L}{\partial W} = \frac{\partial}{\partial W} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial W}$
- $\frac{\partial L}{\partial W}$ solved!




입력 층
 x_t
 은닉 층
 $a_t = Ux_t + Wh_{t-1} + b$
 $h_t = \phi(a_t)$

출력 층
 $o_t = Vh_t + c$
 $f_t = f(o_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{U}} = \frac{\partial}{\partial \mathbf{U}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{U}}$$




입력 층 $\mathbf{x}_t$ 은닉 층 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$ $\mathbf{h}_t = \phi(\mathbf{a}_t)$	출력 층 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$ $\mathbf{f}_t = f(\mathbf{o}_t)$
--	--

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{U}} = \frac{\partial}{\partial \mathbf{U}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{U}}$$

$$\frac{\partial L_1}{\partial \mathbf{U}} = \frac{\partial L_1}{\partial \mathbf{f}_1} \frac{\partial \mathbf{f}_1}{\partial \mathbf{o}_1} \frac{\partial \mathbf{o}_1}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{U}}$$



입력 층
 x_t
 은닉 층
 $a_t = \mathbf{U}x_t + \mathbf{W}h_{t-1} + \mathbf{b}$
 $h_t = \phi(a_t)$


출력 층
 $o_t = \mathbf{V}h_t + \mathbf{c}$
 $f_t = f(o_t)$

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{U}} = \frac{\partial}{\partial \mathbf{U}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{U}}$$

$$\begin{aligned} \frac{\partial L_2}{\partial \mathbf{U}} &= \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{U}} \\ &+ \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{U}} \\ &= \frac{\partial L_2}{\partial \mathbf{f}_2} \frac{\partial \mathbf{f}_2}{\partial \mathbf{o}_2} \frac{\partial \mathbf{o}_2}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \left(\frac{\partial \mathbf{a}_2}{\partial \mathbf{U}} + \frac{\partial \mathbf{a}_2}{\partial \mathbf{h}_1} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{U}} \right) \end{aligned}$$




입력 층 $\mathbf{x}_t$	출력 층 $\mathbf{o}_t = \mathbf{V}\mathbf{h}_t + \mathbf{c}$
은닉 층 $\mathbf{a}_t = \mathbf{U}\mathbf{x}_t + \mathbf{W}\mathbf{h}_{t-1} + \mathbf{b}$	$\mathbf{f}_t = f(\mathbf{o}_t)$
$\mathbf{h}_t = \phi(\mathbf{a}_t)$	

7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

$$\frac{\partial L}{\partial \mathbf{U}} = \frac{\partial}{\partial \mathbf{U}} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial \mathbf{U}}$$


$$\begin{aligned} \frac{\partial L_3}{\partial \mathbf{U}} &= \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{a}_3}{\partial \mathbf{U}} \\ &+ \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{U}} \\ &+ \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{U}} \\ &= \frac{\partial L_3}{\partial \mathbf{f}_3} \frac{\partial \mathbf{f}_3}{\partial \mathbf{o}_3} \frac{\partial \mathbf{o}_3}{\partial \mathbf{h}_3} \frac{\partial \mathbf{h}_3}{\partial \mathbf{a}_3} \left(\frac{\partial \mathbf{a}_3}{\partial \mathbf{U}} + \frac{\partial \mathbf{a}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{a}_2}{\partial \mathbf{U}} \right. \\ &\quad \left. + \frac{\partial \mathbf{a}_3}{\partial \mathbf{h}_2} \frac{\partial \mathbf{h}_2}{\partial \mathbf{a}_2} \frac{\partial \mathbf{h}_1}{\partial \mathbf{a}_1} \frac{\partial \mathbf{a}_1}{\partial \mathbf{U}} \right) \end{aligned}$$



7.2 순환신경망의 학습

■ 시간펼침 오류 역전파(backpropagation through time, BPTT)

- $\frac{\partial L_1}{\partial U} = \frac{\partial L_1}{\partial f_1} \frac{\partial f_1}{\partial o_1} \frac{\partial o_1}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial U}$
- $\frac{\partial L_2}{\partial U} = \frac{\partial L_2}{\partial f_2} \frac{\partial f_2}{\partial o_2} \frac{\partial o_2}{\partial h_2} \frac{\partial h_2}{\partial a_2} \left(\frac{\partial a_2}{\partial U} + \frac{\partial a_2}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial U} \right)$
- $\frac{\partial L_3}{\partial U} = \frac{\partial L_3}{\partial f_3} \frac{\partial f_3}{\partial o_3} \frac{\partial o_3}{\partial h_3} \frac{\partial h_3}{\partial a_3} \left(\frac{\partial a_3}{\partial U} + \frac{\partial a_3}{\partial h_2} \frac{\partial h_2}{\partial a_2} \frac{\partial a_2}{\partial U} + \frac{\partial a_3}{\partial h_2} \frac{\partial h_2}{\partial a_2} \frac{\partial a_2}{\partial h_1} \frac{\partial h_1}{\partial a_1} \frac{\partial a_1}{\partial U} \right)$
- $\frac{\partial L}{\partial U} = \frac{\partial}{\partial U} \sum_{t=1}^3 L_t = \sum_{t=1}^3 \frac{\partial L_t}{\partial U}$
- $\frac{\partial L}{\partial U}$ solved!



입력 층
 x_t
 은닉 층
 $a_t = Ux_t + Wh_{t-1} + b$
 $h_t = \phi(a_t)$

출력 층
 $o_t = Vh_t + c$
 $f_t = f(o_t)$

7.2 순환신경망의 학습

■ 오차 신호 희석 문제 (gradient vanishing problem)

- $\frac{\partial L_t}{\partial U} = \frac{\partial L_t}{\partial f_t} \frac{\partial f_t}{\partial o_t} \frac{\partial o_t}{\partial h_t} \frac{\partial h_t}{\partial a_t} \left(\frac{\partial a_t}{\partial U} + \frac{\partial a_t}{\partial a_t} \frac{\partial h_{t-1}}{\partial a_{t-1}} \frac{\partial a_{t-1}}{\partial U} + \frac{\partial h_{t-1}}{\partial a_t} \frac{\partial a_{t-1}}{\partial a_{t-1}} \frac{\partial U}{\partial U} + \frac{\partial a_t}{\partial a_t} \frac{\partial h_{t-1}}{\partial a_{t-1}} \frac{\partial a_{t-1}}{\partial h_{t-2}} \frac{\partial h_{t-2}}{\partial a_{t-2}} \frac{\partial a_{t-2}}{\partial U} + \dots \right)$
- **활성화함수의 도함수 값**
- f_t 를 학습할 때, $\mathbf{x}_{t-n}$ 와 $\mathbf{h}_{t-n}$ 를 학습에 반영하려면 활성화함수의 도함수 값을 n 번 곱해야 한다.

- Sigmoid의 도함수 ($\in (0,0.5]$)
 - Sigmoid의 도함수를 10번 곱하면?
 - $0.5^{10} = 0.0009765625$
 - $0.25^{10} = 9.5367431640625 \times 10^{-7}$
 - 0에 가까운 값이 나온다.
 - Sigmoid는 순환신경망에서 사용되면 근방의 정보만 반영하여 학습함. 데이터의 순서를 학습하지 못함
 - 일반적으로 우리가 다루는 순서 데이터는 다수(대략 10개 이상)의 정보를 다룰 수 있어야 순환신경망 활용이 의미가 있음.
- 오차 신호 희석 문제를 해결하기 위해서 ReLU를 활성화 함수로 활용할 수 있다.

7.3 장단기 메모리망(LSTM) (1/5)

■ 순환신경망의 단점

- Exploding/vanishing gradient problem: 시간펼침 오류역전파 알고리즘에서의 시간에 대한 역전파 에러 신호가 급격히 증가되거나 급격히 줄어듬.

■ 해결

- 장단기 메모리(Long-Short Term Memory, LSTM) 신경망 모델

■ 장단기 메모리(Long-Short Term Memory, LSTM) 신경망 모델

■ 쓰임

- 언어 모델링(Zaremba et al., 2014)
- 기계번역(Yeung et al., 2016)
- 음성신호 모델링(Sak et al., 2014)
- 비디오 데이터 분석(Donahue et al., 2017)

■ 구조

- CEC (constant error carousel, 상수 오류 회전기) 메모리 셀(cell)
- 세 개의 게이트(gate)
- 여러 연결선
- 그림 7.7 (Graves & Schmidhuber, 2005)

7.3 장단기 메모리망(LSTM) (2/5)




그림 7.6 기본 순환신경망에서 발생하는 오차신호 소실 문제의 도식화(Graves, 2013).

노드의 음영은 $t=1$ 에서의 입력에 대해 시간 흐름에 따른 민감도이다(어두울수록 더 민감함을 의미). 시간이 지나며 새로운 입력값이 은닉층의 활성도를 덮어쓰면서 민감도가 급격히 감소하고, 결과적으로 망은 최초의 입력값을 '잊어버린다'.

7.3 장단기 메모리망(LSTM) (3/5)





그림 7.7 장단기 메모리 신경망의 기본 단위인 메모리 블록의 구성 (Graves & Schmidhuber, 2005)


(a) 셀 메모리를 중심으로 입력(input), 출력(output), 망각(forget) 게이트로 구성된다. 표준 모델에서는 (b)와 같이 블록의 입력은 현재 입력 벡터와 이전 셀 상태 벡터만을 고려한다.

7.3 장단기 메모리망(LSTM) (4/5)


■ 장단기 메모리(Long-Short Term Memory, LSTM) 신경망 모델

■ 계산식

- $\mathbf{i}_t = \mathbf{U}_i \mathbf{x}_t + \mathbf{W}_i \mathbf{h}_{t-1} + \mathbf{b}_i$
- $\mathbf{g}_t = \mathbf{U}_g \mathbf{x}_t + \mathbf{W}_g \mathbf{h}_{t-1} + \mathbf{b}_g$
- $\mathbf{f}_t = \mathbf{U}_f \mathbf{x}_t + \mathbf{W}_f \mathbf{h}_{t-1} + \mathbf{b}_f$
- $\mathbf{o}_t = \mathbf{U}_o \mathbf{x}_t + \mathbf{W}_o \mathbf{h}_{t-1} + \mathbf{b}_o$
- $\mathbf{c}_t = \sigma(\mathbf{f}_t) \odot \mathbf{c}_{t-1} + \sigma(\mathbf{i}_t) \odot \phi(\mathbf{g}_t)$
- $\mathbf{h}_t = \sigma(\mathbf{o}_t) \odot \phi(\mathbf{c}_t)$
 - 순서 데이터: $\mathbf{X} = [\mathbf{x}_1 \ \dots \ \mathbf{x}_T]^T$
 - $\sigma = \text{sigmoid}, \phi = \tanh$
 - $\odot$: 행렬의 원소간 (elementwise) 곱셈 연산
 - $\mathbf{U}_y \in \mathbb{R}^{N_h \times N_x}, \mathbf{W}_y \in \mathbb{R}^{N_h \times N_h}, \mathbf{b}_y \in \mathbb{R}^{N_h}$
 - $y \in \{\mathbf{i}, \mathbf{g}, \mathbf{f}, \mathbf{o}\}$
 - GPU로 효율적으로 계산할 수 있다.



(a)



(b)

장단기 메모리 표준 모델에서의 시간펼침 오류역전파 과정과 경사도 계산식은 다음의 문헌을 참조 (Graves & Schmidhuber, 2005; Greff et al., 2017).

7.3 장단기 메모리망(LSTM) (5/5)




그림 7.8 LSTM에서의 미분 정보 보존 효과에 대한 도식(Graves, 2012).

노드 음영의 의미는 그림 7.5와 동일하다. 은닉노드의 입력, 망각, 출력 게이트가 각각 노드의 하단, 좌측, 상단에 작은 원으로 표시되었으며, 열린 상태(O)와 닫힌 상태(-)로 간략히 표기하였다. 최초의 입력값은 망각 게이트가 열려 있고 입력 게이트가 닫혀 있는 한 기억이 유지되며, 출력 게이트를 열고 닫는 것만으로 셀의 내용에 영향을 주지 않고 출력을 할 수 있다.

7.4 장단기 메모리망의 변형과 확장

■ GRU (Gated Recurrent Unit)

- 개별 순환망 블록이 각각 다른 시간 단위에서의 연관 관계를 파악하는 것을 추구
- LSTM과 비교하여 단순화된 구조
- GRU에는 별도의 셀 메모리가 없으며, 블록 내부의 정보 흐름은 리셋(r) 게이트와 업데이트(z) 게이트로 조절된다.
- LSTM과 GRU의 유의미한 성능 차는 없는 것으로 보고되고 있다 (Chung et al., 2014; Jozefowicz et al.; 2015, Greff et al., 2017).

■ GRU의 계산식

- $\mathbf{r}_t = \mathbf{U}_r \mathbf{x}_t + \mathbf{W}_r \mathbf{h}_{t-1} + \mathbf{b}_r$
- $\mathbf{z}_t = \mathbf{U}_z \mathbf{x}_t + \mathbf{W}_z \mathbf{h}_{t-1} + \mathbf{b}_z$
- $\tilde{\mathbf{h}}_t = \phi(\mathbf{U}_h \mathbf{x}_t + \mathbf{W}_h (\sigma(\mathbf{r}_t) \odot \mathbf{h}_{t-1}) + \mathbf{b}_h)$
- $\mathbf{h}_t = \sigma(\mathbf{z}_t) \odot \mathbf{h}_t + (1 - \sigma(\mathbf{z}_t)) \odot \tilde{\mathbf{h}}_t$
 - 순서 데이터: $\mathbf{X} = [\mathbf{x}_1 \ \dots \ \mathbf{x}_T]^T$
 - $\sigma = \text{sigmoid}, \phi = \text{tanh}$
 - $\odot$: 행렬의 원소간 (elementwise) 곱셈 연산
 - $\mathbf{U}_y \in \mathbb{R}^{N_h \times N_x}, \mathbf{W}_y \in \mathbb{R}^{N_h \times N_h}, \mathbf{b}_y \in \mathbb{R}^{N_h}$
 - $y \in \{\mathbf{r}, \mathbf{z}, \mathbf{h}\}$

7.4 장단기 메모리망의 변형과 확장

- 뉴럴튜링머신(Neural Turing Machine)
 - 기억장치에서 읽고 쓰는 과정까지 학습 (→ 9장)
- 주의집중(attention)
 - 이전 단계의 입력값이나 출력값, 또는 다른 순환신경망의 출력값을 참조하되 서열 상의 위치/시간별 가중치를 달리 하는 방식으로 특정 내용에 대해 주의집중을 하고, 이를 통해 선택적이고 집중적인 학습을 하는 과정
 - 인코더디코더 모델
- 뉴럴프로그래머(Neural Programmer)
 - 프로그램을 정확한 사례 없이도 학습을 통해 자동으로 구축하는 모델
 - 순환신경망은 일련의 연산을 조정하는 컨트롤러 역할을 수행

7.5 순환신경망의 활용 (1/4)

■ 활용 사례

- 언어 모델 (language model)
 - 문맥을 통해 다음 단어를 예측하여 생성
- 음성 인식
 - 음성 신호에서 낱소리를 파악하는 단계 이후 낱소리를 연결하여 단어와 문장으로 인식하는 단계에 언어 모델
- 문장 생성
 - 문맥을 통해 다음 단어를 예측하여 생성하는 언어 모델(language model)
 - n-gram vs. RNN 비교.
 - n-gram: 문맥 범위가 고정되고 문맥이 명시적.
 - RNN: 문맥 범위가 변화하고 문맥이 암묵적.

7.5 순환신경망의 활용 (2/4)





그림 7.9 순환신경망의 적용 사례

딥러닝 기반 종단학습 음성인식모델. 순환신경망 모델은 양방향 GRU의 다층 구조가 적용되었다(Amodei et al., 2015). 하나의 순환신경망이 영어와 중국어 음성을 모두 인식한다.

7.5 순환신경망의 활용 (3/4)

■ 도약 연결(Skip-connection)

- 입력에서 모든 은닉층으로 연결되거나 각 은닉층에서 출력으로 연결
- 오차 신호 소실(vanishing gradient) 문제를 완화



입력서열 $\mathbf{X}$ 의 확률

$$P(\mathbf{X}) = \prod_{t=1}^T P(\mathbf{x}_{t+1}|\mathbf{y}_t)$$

입력서열 $\mathbf{X}$ 의 손실함수

$$L(\mathbf{X}) = - \sum_{t=1}^T \log(\mathbf{x}_{t+1}|\mathbf{y}_t)$$

그림 7.10 문서 생성을 위한 딥 순환신경망 예측망의 구조 (Graves, 2013)

왼은 층을 나타내고 실선은 가중치 연결을 나타내고 점선은 예측을 나타낸다.

7.5 순환신경망의 활용 (4/4)

```
<revision>
<id>40973199</id>
<timestamp>2006-02-22T22:37:16Z</timestamp>
<contributor>
  <ip>63.86.196.111</ip>
</contributor>
<minor />
<comment>redire paget --&gt; captain */</comment>
<text xml:space="preserve">The "'Indigence History'" refers to the author-
ity of any obscure albinism as being, such as in Aram Missolmus'.[http://www.b
bc.co.uk/starce/cr52.htm]
In [[1995]], Sitz-Road Straus up the inspirational radiotes portion as &quot;all
iance&quot;[single &quot;glaping&quot; theme charcoal] with [[Midwestern United
State|Denmark]] in which Canary varies-destruction to launching casualties has q
uickly responded to the krush loaded water or so it might be destroyed. Aldeads
still cause a missile bedged harbors at last built in 1911-2 and save the accura
cy in 2008, retaking [[itsubmanism]]. Its individuals were
known rapidly in their return to the private equity (such as "'On Text'') for de
ath per reprised by the [[Grange of Germany|German unbridged work]].
```

```
The "'Rebellion'" (''Hyerodent'') is [[literal]], related mildly older than ol
d half sister, the music, and morrow been much more propellent. All those of [[H
amas (mass)|sausage trafficking]]s were also known as [[Trip class submarine|''S
ante'' at Serassim]]; ''Verra'' as 1865&ndash;682&ndash;831 is related t
o ballistic missiles. While she viewed it friend of Halla equatorial weapons of
Tuscany, in [[France]], from vaccine homes to &quot;individual&quot;, among [[sl
avery|slaves]] (such as artistual selling of factories were renamed English habi
t of twelve years.)
```

```
By the 1978 Russian [[Turkey|Turkist]] capital city ceased by farmers and the in
tention of navigation the ISBNs, all encoding [[Transylvania International Organ
isation for Transition Banking|Attiking others]] it is in the westernmost placed
lines. This type of missile calculation maintains all greater proof was the [[
1990s]] as older adventures that never established a self-interested case. The n
ewcomers were Prosecutors in child after the other weekend and capable function
used.
```

```
Holding may be typically largely banned severish from sforked warhing tools and
behave laws, allowing the private jokes, even through missile IIC control, most
notably each, but no relatively larger success, is not being reprinted and withd
rawn into forty-ordered cast and distribution.
```

```
Besides these markets (notably a son of humor).
```

```
Sometimes more or only lowed &quot;80&quot; to force a suit for http://news.bbc.
co.uk/1/sid9kcid/web/9960219.html ''[[#10:82-14]]''.
&lt;blockquote&gt;
```

```
==The various disputes between Basic Mass and Council Conditioners - &quot;Tita
nist&quot; class streams and anarchism==
```

```
Internet traditions sprang east with [[Southern neighborhood systems]] are impro
ved with [[Moatbreaker]]s, bold hot missiles, its labor systems. [[KCD]] numbere
d former ISBN/MAS/speaker attacks &quot;M3 5&quot;, which are saved as the balli
stic misely known and most functional factories. Establishment begins for some
range of start rail years as dealing with 161 or 18,950 million [[USD-2]] and [[
covert all carbonate function]]s (for example, 70-93) higher individuals and
missiles. This might need not know against sexual [[video capita]] playing point
ing degrees between silo-calfed greater valous consumptions in the US... header
can be seen in [[collectivist]].
```

```
== See also ==
```

그림 7.11 장단기 메모리 신경망과 Wikipedia 데이터를 통해 생성된 샘플 (Graves, 2013)

- tag 시작과 끝이 잘 대응됨.
 - <id>400973199</id>
- tag 의미에 맞게 의미가 들어감
 - <timestamp>2006-02-22T22:37:16Z</timestamp>

요약

■ 순환신경망의 구조

- 은닉층에 재귀적인 연결이 있는 다층퍼셉트론
- 변형: 다층 순환신경망, 잔차연결 추가, 양방향 순환신경망

■ 순환신경망의 학습

- 시간펼침 오류 역전파, 다변수 연쇄법칙
- 오류 신호 희석 문제

■ 장단기 메모리망(LSTM)

- 오류 신호 희석 문제를 해결

■ 장단기 메모리망의 변형과 확장

- GRU, 뉴럴튜링머신, 주의집중, 뉴럴프로그래머

■ 순환신경망의 활용

- 언어 모델, 음성 인식, 문장 생성
- 도약 연결

참고문헌

- (Chung et al., 2014) Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling. *arXiv:1412.3555v1*.
- (Donahue et al., 2017) Donahue, J., Hendricks, L. A., Rohrbach, M., Venugopalan, S., Guadarrama, S., Saenko, K., & Darrell, T. (2017). Long-term recurrent convolutional networks for visual recognition and description. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 39(4), 677-691.
- (Goodfellow et al., 2016) Goodfellow, I., Bengio, Y., Courville, A. (2016). *Deep Learning*. MIT press.
- (Graves, 2013) Graves, A. (2013). Generating sequences with recurrent neural networks. *arXiv:1308.0850*.
- (Graves & Schmidhuber, 2005) Graves, A. & Schmidhuber, J. (2005). Framewise phoneme classification with bi directional LSTM and other neural network architectures. *Neural Networks*, 18(5-6), 602-610.
- (Greff et al., 2017) Greff, K., Srivastava, R. K., Koutník, J., Steunebrink, B. R., & Schmidhuber, J. (2017). LSTM: A search space odyssey. *IEEE Transactions on Neural Networks and Learning Systems*, (in press).
- (Hihi & Bengio, 1995) Hihi, E. S. & Bengio, Y. (1995). Hierarchical recurrent neural networks for long-term Dependencies. *Advances in Neural Information Processing Systems (NIPS)*, 493-499.
- (Jozefowicz et al., 2015) Jozefowicz, R., Zaremba, W., & Sutskever, I. (2015). Empirical exploration of recurrent network architectures. In *Proceedings of the 32nd International Conference on Machine Learning*, 2342-2350.
- (Neubig, 2017) Neural machine translation and sequence-to-sequence models: A tutorial. *arXiv:1703.01619*.
- (Rumelhart et al., 1986) Rumelhart, D. E., Hinton, G. E., & Williams, R. J. (1986). Learning representations by Back-propagating errors, *Nature*, 323(9): 533-536.
- (Sak et al., 2014) Sak, H., Senior, A., & Beaufays, F. (2014). Long short-term memory recurrent neural network architectures for large scale acoustic modeling. In *Proceedings of the Annual Conference of International Speech Communication Association*, 338-342.
- (Yeung et al., 2016) Yeung, S., Russakovsky, O., Mori, G., & Fei-Fei, L. (2016). End-to-end learning of action detection from frame glimpses in videos. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2678-2687.
- (Zaremba et al., 2014) Zaremba, W., Sutskever, I., and Vinyals O. (2014). Recurrent neural network regularization. *arXiv:1409.2329*.