

Lecture 15: 잔차학습 모델

(교재 Chapter 12 잔차학습 모델)

<기계학습 개론> 2019 강의
서울대학교 컴퓨터공학부
장 병 탁

교재: 장교수의 딥러닝, 홍릉과학출판사, 2017.

Biointelligence Laboratory
School of Computer Science and Engineering
Seoul National University




목차

12.1 딥잔차넷(DRN)	3
12.2 암묵적 앙상블 잔차넷	10
12.3 멀티모달 잔차넷(MRN)	16
12.4 응용사례: 시각대화 챗봇	27
참고: VQA in RoboCup@Home	29
요약	31

12.1 딥잔차넷(DRN) (1/7)

■ 딥잔차넷 구조




아래쪽 넷은 19층의 VGG-19 모델이며, 가운데의 넷은 34층의 깊은 넷을 도식화 한다. 사이 사이에 새로운 층이 추가되었다. 위쪽 넷은 가운데 넷에서 지름 연결선들이 추가된 것을 보여준다.

12.1 딥잔차넷(DRN) (2/7)

- 딥잔차넷으로 아주 깊은 네트워크를 구축함으로써 높은 성능을 기록
- 마이크로소프트 리서치의 Kaiming He 등이 제안함
- 2015년 이미지넷 분류, 탐지, 탐색 및 COCO 대화의 탐지와 분리 분야 우승

Revolution of Depth



12.1 딥잔차넷(DRN) (3/7)

■ 기존의 분류 문제 해결 방법

- 이미지 정보에 대한 경계선 탐지, 히스토그램, K평균 클러스터링 혹은 희소 코딩 등의 전문 지식 활용
- 이러한 전문 지식을 활용하여 요소들을 추가할 수록 분류기 전 단계의 깊이가 깊어진다.

■ 문제점



- 전문가 지식이 필요하다.
- 각 문제마다 수작업으로 만들어야 하는 요소가 있다.

■ 우수한 성능을 위한 깊은 층의 네트워크 구성

- 기존의 깊은 네트워크 학습 방법
 - 많은 데이터 사용
 - ReLU함수 도입
 - 학습 파라미터들의 초기화 전략
 - 배치 정규화 (Batch normalization)
- 위 방법들로 10층 이상의 네트워크를 학습하는데 크게 기여하였다.

12.1 딥잔차넷(DRN) (4/7)

■ 깊이가 깊어지면서 문제 발생




20층과 56층의 넷으로 CIFAR-10 데이터셋에 대한 학습 에러(왼쪽)와 테스트 에러(오른쪽) 곡선. 깊이가 어느 정도 깊어지게 되면 학습 에러가 커지고, 따라서, 테스트 에러도 증가한다.

12.1 딥잔차넷(DRN) (5/7)

■ 아주 깊은 네트워크를 구축하는 방법

- 기존의 얇은 층의 네트워크의 층들을 복사한 후 사이에 새로운 층을 추가
 - 단, 새롭게 추가한 층은 입력 값과 같은 값을 내보낼 수 있도록 파라미터 초기화



딥잔차넷의 잔차 학습 단위에 대한 도식

12.1 딥잔차넷(DRN) (6/7)

■ 딥잔차넷 모델

학습하고자 하는 매핑이 $H(x)$ 라고 한다면,

임의로 비선형함수로 표현할 수 있는 네트워크 수식은 다음과 같다.

$$F(x) := H(x) - x$$



그 수식을 아래와 같은 형태로 네트워크를 만들 $H(x)$ 를 학습하도록 한다.

$$H(x) := F(x) + x$$

따라서 새롭게 추가된 네트워크 $F(x)$ 가 기존의 학습된 네트워크의 성능을 최대한 유지시키면서 잔차 값을 학습함으로써 더 좋은 성능을 낼 수 있도록 만들어준다.

12.1 딥잔차넷(DRN) (7/7)

- 지름 연결선을 이용한 깊은 넷으로 층수를 늘릴 때의 문제를 해결
 - 지름 연결선을 이용한 깊은 넷은 얇은 넷보다 상대적으로 높은 성능을 가진다.



얇은 선은 학습 에러 곡선, 굵은 선은 검증 에러 곡선이다.

왼쪽 그림에서 깊이가 깊은 34층 넷은 에러가 18층 넷보다 큰 반면,

오른쪽 그림의 잔차넷에서는 18층 넷보다 34층 넷에서 보다 나은 성능을 보였다.


12.2 암묵적 앙상블 잔차넷 (1/6)

■ 딥잔차넷의 작동 원리

- 좋은 성능의 원인은 깊이가 아니라는 해석 제기됨
- 지름 연결선들이 정보가 전달되는 길을 기하급수적으로 늘렸고
- 여러 네트워크들을 덧셈 형태로 암묵적인 앙상블 모델로 해석할 수 있다.


■ 딥잔차넷의 해석

- n 개의 잔차 층들을 입력과 출력을 연결하는 $O(2^n)$ 개의 암묵적인 연결선들로 해석할 수 있다.



(a) Conventional 3-block residual network

=




(b) Unraveled view of (a)

(a) 전형적인 3층의 잔차넷을 나타낸다.

(b) 지름 연결선이 유발하는 정보 흐름의 경우들을 도식화하였다.

12.2 암묵적 앙상블 잔차넷 (2/6)

- 비선형 함수를 합성함수의 합으로 표현될 수 있다는 해석을 위한 실험
- 실험 1: 일부 층을 제거하여 성능 변화를 관찰




파란 선은 110층의 잔차넷,
주황색 선은 VGG 넷을 나타낸다.

x축에 표시된 인덱스의 넷 층을 삭제하였을 때 성능의 변화를 관찰하였다.


VGG 넷에서는 어느 위치에서든지 심각한 성능 손상을 가져왔지만, 잔차넷의 경우 거의 동일한 성능을 유지하였다. 단, 특징 벡터의 차원이 변경되는 구간에서 소폭의 성능 감소가 관찰된다.

12.2 암묵적 앙상블 잔차넷 (3/6)

■ 실험 2: 잔차넷의 층 변화에 대한 앙상블 모델과의 유사한 특성 비교



(a)




(b)

- (a) 잔차넷에서 제거된 층 수에 따라 에러가 점차적으로 변화하는 것을 관찰할 수 있다.
(b) 잔차넷의 층들을 무작위로 뒤섞을 때의 에러 변화를 관찰하였다. 재정렬된 정도 (Kendall Tau correlation)가 증가함에 따라 에러가 점차적으로 변한다. 이러한 결과는 앙상블 모델에서 쉽게 관측될 수 있는 모습이다.

12.2 암묵적 앙상블 잔차넷 (4/6)


- 실험 3: 얇은 층의 넷들의 앙상블 모델로 여겨질 수 있는가에 대한 실험



- (a) 잔차넷에서 표현 가능한 경로 길이의 분포는 이항분포로 표현될 수 있다.
- (b) 첫번째 층에서 다른 길이의 경로를 지나면서 에러 경사가 나타나는지 살펴보았다. 경로에 놓여있는 모듈 수에 따라 대략적으로 지수적으로 감소함을 관찰하였다. (y축은 로그 척도)

12.2 암묵적 앙상블 잔차넷 (5/6)

■ 실험 3 (계속)



(c)


(c) 앞의 두 함수를 곱하여 특정 길이의 경로에서 얼마만큼의 에러 경사가 기여하는지 관찰하였다. 20층 이상의 경로는 에러 경사가 충분히 기여하지 못하였다.

따라서, 잔차넷은 상대적으로 얇은 층의 여러 넷으로 이루어진 암묵적인 앙상블 모델로 볼 수 있다.

12.2 암묵적 앙상블 잔차넷 (6/6)

■ 암묵적 앙상블 후속 연구


- Dropout 정규화 방법과 보다 큰 차원의 은닉 층으로 구성된 잔차넷
- 잔차 연결선을 재귀적으로 연결하여 성능 향상
- 기존의 잔차넷을 다중모달로 확장하여 시각적 질의응답을 위한 멀티모달 잔차 학습방법



도식화된 잔차넷 모듈

12.3 멀티모달 잔차넷(MRN) (1/8)

- 둘 이상의 모달리티 입력이 주어지는 다중모달 학습으로 확장한 연구
- 딥잔차넷을 다중모달로 확장할 때 고려사항
 - 잔차 학습을 위한 비선형 다중모달 결합 함수의 정의
 - 지름 연결선의 선택




다중모달 학습의 예시, 시각 질의 응답

12.3 멀티모달 잔차넷(MRN) (2/8)

■ 비선형 멀티모달 결합함수 정의

$$f(x, y) = \tanh(W_x x) \odot \tanh(W_y y)$$

각 입력을 선형사영 후 하이퍼볼릭 탄젠트 활성화 함수를 적용한다.
원소곱을 이용하여 두 모달리티의 정보가 결합된 표현을 얻는다.



다중모달 잔차넷에서 사용된 비선형 다중모달 결합 함수.
기호 $\odot$ 는 같은 크기의 두 벡터 간의 원소곱을 나타낸다.

12.3 멀티모달 잔차넷(MRN) (3/8)

■ 지름 연결선의 선택

- 여러 선행 연구들에서 지름 연결선으로 해석할 수 있는 구조가 질의 벡터에 대하여 연결된 것을 관찰할 수 있다.
- 이러한 연구 결과와 일관되게 다중모달 잔차넷에서도 적용되었고 다음의 식으로 표현될 수 있다.

$$f(Q, V) = \tanh(W_Q Q) \odot \tanh(W_V V) + W_S Q$$

지름 연결선 $W_S Q$

출력 값의 차원 크기를 일치시키기 위한 선형 사영 W_S

12.3 멀티모달 잔차넷(MRN) (4/8)

■ 멀티모달 잔차넷 모델

$$H_L(q, v) = W_q q + \sum_{l=1}^L W_{F^{(l)}} F^{(l)}(H_{l-1}, v) \quad H_0 \text{ 질의 벡터로 정의}$$

L 개의 층을 가진 다중모달 잔차넷의 수식표현


(l) 번째 층의 비선형 다중모달 결합함수 $F^{(l)}$ 은 이전 층의 출력과 시각 정보 v 를 입력으로 갖는다.

- 지름 연결선으로 인하여 깊은 층에서 반복적으로 나타나는 비선형 다중모달 결합 함수들은 덧셈 형태가 된다.
- 지름 연결선으로 질의 벡터는 선형 사영 후 다시 더해진다.

12.3 멀티모달 잔차넷(MRN) (5/8)

■ 학습 단위 모델

- Q 는 자연어 텍스트 문장을 벡터로 임베딩
 - RNN 모델의 마지막 은닉 벡터를 이용해서 값을 얻을 수 있다.
 - GRU를 사용
- V는 시각 정보를 벡터로 임베딩
 - CNN 모델의 마지막 컨볼루션 층의 출력 벡터를 이용해서 얻을 수 있다.
- ResNet-152 모델 사용



다중모달잔차넷에서 사용된 학습단위모델.
기호 $\oplus$ 는 같은 크기의 두 벡터간의 덧셈을 나타낸다.


12.3 멀티모달 잔차넷(MRN) (6/8)

■ 전체 구조

- 학습 단위 모델을 3개 층으로 쌓음
- 각 단위 모델의 결과물은 다음 단위 모델의 입력 값을 위한 새로운 질의 벡터로 입력
- 시각 정보는 각 층에 동일한 값을 다시 입력

■ 특징

- CNN 모델의 파라미터 재조정
 - 추가적인 선형 사영과 비선형 활성화 함수를 적용함으로써 시각 정보에 대한 학습 효율을 향상시킴



멀티모달 잔차넷의 전체 구조

12.3 멀티모달 잔차넷(MRN) (7/8)

■ 멀티모달 잔차넷의 정보 선택 시각화

- 경사도를 이용한 오차역전파 방법을 응용
- 시각 정보 V 는 질의 정보 Q 와의 원소곱에 의해 중간 정보 F 를 출력한다. 시각 정보와 중간 정보의 차 값은 질의 정보에 의해 변화된 양을 나타내며 아래의 식을 이용해 변화된 양을 입력 이미지 J 로 역전파할 수 있다.

$$L_{att} = \frac{1}{2} \|V - F\|^2 \qquad \frac{\partial L_{att}}{\partial J} = \frac{\partial V}{\partial J} (V - F)$$

효과적인 시각화를 위해 F 를 고정된 상수 취급하여 계산하고, 도함수의 연쇄 법칙을 이용해서 역전파된 경사도의 절대값을 시각화한다.

12.3 멀티모달 잔차넷(MRN) (8/8)

■ 멀티모달 잔차넷의 정보 선택 시각화



입력 영상 원본

첫번째 원소곱

두번째 원소곱

세번째 원소곱

좌로부터 순서대로 입력 이미지, 첫 번째 원소곱, 두번째 원소곱, 세번째 원소곱에 의한 시각화이다. 'What sport is this?' 라는 질문에 'surfing'이라는 답을 얻었다.

각 원소곱에 의한 시각화 과정을 보면 정보 선택을 위해 Attention 되는 부분을 볼 수 있다.

원소곱이 나아갈수록 질의에 더욱 적절한 attention이 이루어지고 있음을 확인할 수 있다.

12.4 응용사례: 시각대화 챗봇 (1/4)

■ 캠티(Cambot)

- 다중모달 잔차넷을 응용한 시각대화 챗봇
- 카메라를 이용한 상황인지와 음성으로 질문한 내용에 답할 수 있다.
- 로봇, 웹 서버, 추론 서버로 구성된다.



■ 캠티의 구성요소 - 로봇

- 필수 요소: 마이크와 카메라, 스피커 장치가 구성된 로봇
 - 위의 필수 요소가 탑재된 PC 혹은 노트북으로 로봇 대체 가능
- 사용자가 질문을 하면 구글 음성인식 서비스를 통해 질의를 텍스트로 변환하고 질문하는 순간 카메라로 사진을 찍어 질의 텍스트와 함께 웹 서버로 전송
- 웹 서버에서 반환 받은 값을 Text To Speech 기술로 대화하듯 응답한다.

12.4 응용사례: 시각대화 챗봇 (2/4)

■ 캤봇의 구성요소 - 웹 서버

- 로봇과 추론 서버를 이어주는 역할을 하며, 다양한 플랫폼에서도 활용가능
- 로봇에서 한국어 질의와 사진 데이터를 받으면 영어로 번역하여 사진과 함께 추론 서버로 전송
- 추론 서버에서 받은 영어 답변을 한국어로 번역 후 로봇으로 전송

■ 캤봇의 구성요소 - 추론 서버


- 다중모달 잔차넷으로 VQA 데이터셋 및 MS-COCO 데이터셋으로 학습
- 입력된 영어 질의와 사진을 통해 응답을 추론하여 웹 서버로 전송



캤봇 구성도

12.4 응용사례: 시각대화 챗봇 (3/4)

■ 캤봇의 개념도



음성으로 주어진 질의는 구글의 Speech-To-Text API를 이용하여 텍스트로 변환되고 로봇에 장착된 카메라를 이용하여 주어진 상황을 이미지로 입력 받는다.

■ 활용 분야

시각이 불편한 사람들을 돕거나 근처 장애물 식별 가능

질의와 함께 사진의 정보 태깅 가능

대용량의 감시카메라 영상 검색 시 질의어를 사용하여 효율적으로 탐색 가능

12.4 응용사례: 시각대화 챗봇 (4/4)

VQA Demo

Multimodal Residual Learning for Visual QA

J.-H. Kim et al., NIPS 2016

Demo by K.-B. Kim

SNU BI Lab.

VQA in RoboCup@Home

[Ha et al., AAAI-2015]

[KimJ et al., NIPS-2016]

[KimK et al., IJCAI-2017]

[KimJ et al., ICLR-2017]


[Lee et al., NIPS-2018]



AUPAIR (SNU): Personal Service Robot

AUPAIR Team (SNU & Surromind Robotics)

*Winning the **RoboCup@Home 2017***



<https://www.youtube.com/watch?v=a2ZJTpbMWsQ>

<http://mnews.join.com/article/21823070#home>

RoboCup@Home

- SNU AUPAIR Robot (Lee et al., 2017) won RoboCup@Home Social Standard Platform league in RoboCup2017.
- The VQA module (Kim et al., ICLR 2017) was used in **Open Challenge** of Stage 2 and **Final Demonstration** (the score of final demo is not shown below).



	Stage 1	Open Challenge	Tour guide	Restaurant	EE-SPSR	Stage 2	Rank
AUPAIR	245.00	178.47	95	40	70	628.47	1
UTS Unleashed!	163.83	121.53	0	0	0	285.36	2
SPQReL	96.67	130.56	0	10	20	257.22	3
KameRider	91.67	136.81	0	15	0	243.47	4
UChile Peppers	81.67	0.00				81.67	5
UvA@Home	67.50	0.00				67.50	6
ToBI@Pepper	66.25	0.00				66.25	7
Maximum	700	250		285	250	1485	

<https://www.robocup2017.org/eng/results.html>

요약

■ 딥잔차넷(DRN)

- 깊은 네트워크를 쌓는데 있어서 문제 발생
- 지름 연결선을 이용하여 기하 급수적으로 깊은 네트워크를 구축
- 2015년 이미지넷 분류 대회 등 우승

■ 암묵적 앙상블 잔차넷

- 딥잔차넷의 작동 원리를 암묵적 앙상블 모델로 해석
- 암묵적 앙상블 모델로 여겨질 수 있는가에 대한 실험

■ 다중모달 잔차넷(MRN)

- 두 종류 이상의 입력이 주어지는 다중모달 학습으로 확장
- 비선형 다중모달 결합함수 정의 및 지름 연결선의 선택
- 자연어 정보 및 시각 정보를 활용한 시각적 질의응답

■ 응용 사례

- 시각대화 챗봇, 캠봇, AUPAIR 로봇
- 로봇, 웹 서버, 추론 서버로 구성

질문

- 잔차학습 모델을 이용하여 초고층의 심층신경망을 구축하는 방법을 설명하시오.
- 딥잔차넷이 초고층임에도 불구하고 과다학습 현상이 나타나지 않는 이유는 무엇인가? 딥잔차넷의 작동 원리는 무엇인가?
- 딥잔차넷은 암묵적인 앙상블 모델로 볼수 있다. 이를 뒷바침 하는 실험 결과들을 예시하고 설명하시오.
- 잔차넷 모델을 다중모달 정보를 학습하는 방법을 설명하시오. 이 때 가장 고려하여야 하는 점은 무엇인가?
- 다중모달 잔차넷에서 정보 선택을 시각화하는 Attention 방법을 설명하시오.
- 다중모델 잔차넷을 이용하여 시각대화 챗봇을 만드는 방법을 설명하시오. 시각대화 챗봇은 어떤 응용에 활용될 수 있는가?
- RoboCup@Home 대회에 출전하는 홈서비스 인공지능로봇을 개발하고자 한다. 딥러닝/머신러닝 기술을 적용하는 활용 사례를 세가지 이상 제안하시오.